

ML v2

Mehmet Fatih AMASYALI
Hesaplamaalı Anlambilim
Ders Notları
BÖLÜM 4



İçerik

- Aktif Öğrenme (Active Learning)
- Yarı Eğitici Öğrenme (Semi-supervised Learning)
- Öğrenmenin Transferi (Transfer Learning)
- Çok görevli eğitim (Multi-task Learning)
- Aktif örnekleme (Active Sampling)
- İnsan ve makine işbirliği (Human in loop)
- Az sayıda örnekle eğitim (zero / one shot Learning)
- Veri zenginleştirme (data augmentation)
- ML algoritmalarını kandırmak (Adversarial Attacks)
- Planlı öğrenme (Curriculum Learning)
- Hayat boyu öğrenme (Lifelong learning)
- Kendi kendine öğrenme (Self Supervised Learning)
- Karşıtsal Öğrenme (Contrastive Learning)
- Bağlam içi öğrenme (In context learning)



Aktif Öğrenme (Active Learning)

- Eğitim örneklerinin etiketlerinin başta belli olmadığı, algoritmanın etiketini istediği örnekleri seçmesidir.
- Amaç: Veri etiketleme maliyetini azaltmak
- Yöntem: Tüm eğitim seti yerine bir kısmını kullanmak. Belirli bir test seti üzerinde; tüm eğitim setini kullanmış olmamıza göre benzer, kabul edilebilir derecede düşük ya da daha yüksek başarı elde etmek




Aktif Öğrenme Adımlar

- A: Küçük bir eğitim setiyle (E) başla. (eğitim kümesinin az bir kısmının etiketlerini iste)
- B: Bir model üret. Bu modele göre etiketsiz eğitim örneklerine (EE) dair tahminlerini üret.
- C: Bu tahminlere göre bu örneklerden bir kısmını seç (tahmin varyasyonuna göre) ve etiketlerini iste. (EE'den çıkar, E'ye ekle)
- B ve C adımlarını tekrar et



Aktif Öğrenme

- Tüm eğitim kümesi
- Λ -Mevcut eğitim kümesi
- ϕ -Seçilen örnekler




Aktif Öğrenme Sorular

- İlk eğitim seti (E) nasıl seçilebilir? Önemi var mı?
- EE'deki örneklerin sınıflandırma problemlerinde tahmin varyasyonu nasıl hesaplanır?
- Tahmin varyasyonu Regresyon problemlerinde nasıl ölçülebilir?
- Tahmin varyasyonu çok (zor) mu az (kolay) mı olan örnekler seçilmeli (etiketleri istenmeli) ?
- B ve C adımlarının tekrarı ne zaman durmalı?
- C adımında ne kadar örnek eklenmeli?









Kod active_learning.m







önce kolay örnekler









önce kolay örnekler



önce zor örnekler



önce zor örnekler



Aktif Öğrenme Bulgular


- Önce kolay örnekleri eklemek iyileştirmiyor
- Önce zor örnekleri eklemenin yararlı olduğu veri kümeleri var.
- Bazı veri kümelerinde tüm eğitim örnekleri yerine daha az örnekle daha yüksek test başarılarına erişilebiliyor.

[*] daha fazlası için <https://www.manning.com/books/human-in-the-loop-machine-learning>



Yarı Eđiticiili Öğrenme (Semisupervised Learning)

- Modelin oluşturulmasında etiketli verilerin yanında etiketsiz verilerinde kullanıldığı problemlerdir.
- Temel fikir: Elde hem etiketli hem de etiketsiz veriler var. Belirli bir test seti üzerinde, sadece etiketli verileri kullanmak yerine, etiketsizleri de kullanmak daha iyi olur.




Yarı Eđiticiili Öğrenmede Sorular

- Etiketsiz örneklerin tahmini sınıfları nasıl hesaplanır?
- Regresyon problemlerinde nasıl hesaplanır?
- Etiket tahminlerimi tek seferde mi iteratif mi yapalım?
- İteratifte etiketlerin toplamda ne kadarını tahmin edelim?
- İteratifte her bir iterasyonda etiketlerin ne kadarını tahmin edelim?




Kod `semi_supervised_learning.m`


*: Etiketli eğitim
örnekleri
o: etiketi tahmin
edilen eğitim
örnekleri




Orijinal etiketler









Orijinal + batch semi
supervised ile tahmin









Orijinal + iteratif semi
supervised ile tahmin



Yarı Eğitimci Öğrenme denemeler



Yarı Eğitimli Öğrenme denemeler



Yarı Eđiticiili Öğrenme bulgular

- Tahmini etiketleri hiç kullanmamanın da, tek seferde tahmin etmenin de, iteratif tahminin de diğerklerinde iyi olduđu sonuçlar var.
- İteratif tahminde nerede durulacađı etken
- Derin öğrenmede yarı eđiticiili yöntemler:
<https://arxiv.org/pdf/2006.05278.pdf>



Öğrenmenin Transferi


Transfer learning

- Bir problemi çözdükten sonra, benzeri başka bir problemi sıfırdan çözmek yerine önceki verileri, modelleri, parametreleri (gerekliyorsa dönüştürerek) kullanmak
- Amaç: yeni problemi sıfırdan çözmeye göre daha az maliyetli / daha iyi bir çözüm bulmak



Öğrenmenin Transferi

- Neler transfer edilebilir?
 - Veriler (aynen / değiştirilerek)
 - Tüm model
 - Metinler için kelime vektörleri (sabit ya da adaptif)
 - Resimler için CNN filtreleri (sabit ya da adaptif)




[*] <https://arxiv.org/pdf/1311.2901.pdf>



Öğrenmenin Transferi

- Ne zaman işe yarar
 - Eldeki yeni problem için yeterli veri yoksa
 - Eski ve yeni problem ilgili ise




- Aggressive: Çok fazla bilgi transferi
- Benzer bir karakteristik yarı eğitici öğrenme için de söylenebilir




Çok görevli eğitim (Multi-task Learning)

- Aynı anda birden fazla şeyi öğrenmek
- Çok sayıda veri kümesini aynı yapı içinde modellemek
- Hem satranç, hem dama oynayabilen tek bir sistem



Çok görevli eğitim



[*] <http://ruder.io/multi-task/>

[*] <https://arxiv.org/abs/1705.07115>

Çok görevli eğitim

- NLP Decathlon

Examples

Question	Context	Answer	Question	Context	Answer
What is a major importance of Southern California in relation to California and the US?	...Southern California is a major economic center for the state of California and the US...	major economic center	What has something experienced?	Areas of the Baltic that have experienced eutrophication .	eutrophication
What is the translation from English to German?	Most of the planet is ocean water.	Der Großteil der Erde ist Meerwasser	Who is the illustrator of Cycle of the Werewolf?	Cycle of the Werewolf is a short novel by Stephen King, featuring illustrations by comic book artist Bernie Wrightson .	Bernie Wrightson
What is the summary?	Harry Potter star Daniel Radcliffe gains access to a reported £320 million fortune ...	Harry Potter star Daniel Radcliffe gets £320M fortune...	What is the change in dialogue state?	Are there any Eritrean restaurants in town?	food: Eritrean
Hypothesis: Product and geography are what make cream skimming work. Entailment , neutral, or contradiction?	Premise: Conceptually cream skimming has two basic dimensions – product and geography.	Entailment	What is the translation from English to SQL?	The table has column names... Tell me what the notes are for South Australia	SELECT notes from table WHERE 'Current Slogan' = 'South Australia'
Is this sentence positive or negative?	A stirring, funny and finally transporting re-imagining of Beauty and the Beast and 1930s horror film.	positive	Who had given help? Susan or Joan?	Joan made sure to thank Susan for all the help she had given.	Susan



Çok görevli eğitim

Kod `multi_task_learning.m`

- 2 boyutlu, 2 sınıflı 5 veri kümesi için, 10 hidden nöronlu YSA, eşit eğitim süresi, 3 deneme
- single_tr_acc = 1.0000 0.5875 0.8462 0.9714 0.7663
- single_acc = 0.9067 0.5017 0.6923 0.9771 0.7554
- multi_tr_acc = 0.9333 0.5611 0.7483 0.9657 0.7609
- multi_acc = 0.8667 0.4785 0.7343 0.9656 0.7935

- single_tr_acc = 1.0000 0.5479 0.8671 0.9771 0.7989
- single_acc = 0.9467 0.5050 0.7063 0.9656 0.7228
- multi_tr_acc = 0.8133 0.5446 0.7692 0.9600 0.7935
- multi_acc = 0.7200 0.4983 0.7413 0.9656 0.7446

- single_tr_acc = 0.9733 0.5380 0.8112 0.9686 0.7935
- single_acc = 0.9200 0.4521 0.6783 0.9656 0.7772
- multi_tr_acc = 0.9600 0.4785 0.7692 0.9571 0.7446
- multi_acc = 0.9600 0.4884 0.7203 0.9570 0.7772



Bulgu-Yorum


- İyileşmenin olduğu veri kümeleri var.
- Ama genel birşeyler söylemek için çok daha fazla denemeye ihtiyaç var.
- Bir ağ kaç problemi kapsayabilir?
- Ağın karmaşıklığı artarsa?

[*] daha fazlası için: <http://runder.io/multi-task/>




Hiper parametre optimizasyonu

- Hiper parametre uzayının hangi noktalarında deneme yapalım?
 - Izgara (Grid) arama
 - Rasgele arama
 - Bayesian optimization
 - <https://towardsdatascience.com/shallow-understanding-on-bayesian-optimization-324b6c1f7083>
- Eldeki deneme sonuçlarına göre en fazla iyileşme sağlanabilecek değeri tahmin eder



Aktif Örnekleme

- Bayesian optimizasyondan esinlenelim
- Kullanıcıdan input uzayı için yeni örnekler isteyebilir miyiz? (Aktif Örnekleme)
- Aktif öğrenmede etiketsiz verilerin hangilerinin çıkışlarını kullanıcıdan isteyeceğimizi belirliyorduk. Burada örneklerin kendilerini (input ve çıkış) isteyeceğiz.




<https://www.sciencedirect.com/science/article/pii/S2352924516300035>



Kod active_sampling.m

Model varyansının en yüksek olduğu yerler = tahminlere en az güvenilebileceğimiz yerler
Modelin bir noktadaki varyansı, farklı eğitim kümeleri için o noktanın tahminlerinin std si
Buralardan yeni örnek istemeliyiz.



İnsan makine işbirliği

- the combination of human and machine intelligence / Human in loop / weak supervision
- İnsanlar (yavaş, doğru)
 - Veri etiketleyebilir
 - Tahminleri düzeltebilir
 - Tahminler arasından seçim yapabilir
 - 100 sınıftan en olası 5 inden doğru olanı seçebilir
 - Örneklerin ortak bir özelliği için kural verebilir
 - İçinde şu ifade geçenler negatiftir
 - Kedilerin kuyruğu vardır.
- Makineler (hızlı, çok sayıda bilgiyle başa çıkabilirler, az doğru)
 - Tahmin üretebilirler



İnsan makine işbirliği örnek

- Video etiketleme
 - <https://www.youtube.com/watch?v=vbydG78Al8s>
 - <https://www.youtube.com/watch?v=ljl5pAowACc>
- Günümüzde Çeviri
 - Otomatik çeviri + insanlarca düzeltme
- Weak supervision
 - <https://dawn.cs.stanford.edu/2017/07/16/weak-supervision/>
 - Snorkel



İnsan makine işbirliği örnek

- Reinforcement learning from human feedback (RLHF)*
- chatGPT**




Figure 2: A diagram illustrating the three steps of our method: (1) supervised fine-tuning (SFT), (2) reward model (RM) training, and (3) reinforcement learning via proximal policy optimization (PPO) on this reward model. Blue arrows indicate that this data is used to train one of our models. In Step 2, boxes A-D are samples from our models that get ranked by labelers. See Section 3 for more details on our method.



[*] <https://arxiv.org/pdf/1706.03741.pdf> <https://arxiv.org/abs/2009.01325>

[**] <https://openai.com/blog/chatgpt/>

NOVA Research Lab

Az sayıda örnekle eğitim



- Any problem can be treated as a pattern recognition problem if your training data covers a sufficiently dense sampling of the problem space. What's interesting is what happens when your training data is a sparse sampling of the space -- to extrapolate, you will need intelligence.
- <https://twitter.com/fchollet/status/1022822099872698370?s=03>



One-shot learning

Tek çekimle öğrenme

- Eğitim kümesinde her sınıf için tek bir örneğin olduğu problemler





VS



Google'ın Makine Çevirisi

Zero-shot machine translation

- Her olası dil ikilisi için ayrı birer model eğitmek yerine (100 dilden 100 dile)
- $A \rightarrow B$, $B \rightarrow C$ var, $A \rightarrow C$ yok
- Girişler ortak bir katmana
- Çıktılar ortak katmandan



Aynı anlamlı
farklı kaynak dillerdeki
cümlelerin temsilleri



[*] <https://ai.googleblog.com/2016/11/zero-shot-translation-with-googles.html>

Sıfır çekim sınıflandırma

Zero-shot classification [*] , [**]

Yöntem 1:

Sınıfları belirle

Sınıfları temsil eden örnekleri ve temsillerini bul ($X_{i=1:N}$)

Yeni gelen örneğin temsilini bul (K)

K, X_i lerin hangisine en yakınsa sınıfı odur.

Yöntem 2:

BERT vb. bir dil modelini NLI vb. bir veri kümesi ile eğit (modelX).

Sınıfları belirle

Sınıfları temsil eden örnekleri bul ($X_{i=1:N}$)

Yeni gelen örnek : K

“ X_i [sep] K” örneklerini modelX’e ver.

Bunların içinde entailment olasılığı en yüksek olan K’nın sınıfıdır.

Bu metnin konusu {sağlık, spor vb.}

Bu tweet bana {neşeli, hüzünlü vb.} hissettiriyor.



[*] <https://aclanthology.org/D19-1404.pdf>

[**] <https://www.sciencedirect.com/science/article/pii/S0306457323000353>


Veri zenginleştirme

- Yeni eğitim verileri üretmek
- Görüntüler için
- Metin verileri için
- Genel veriler için



Görüntüler için


- Kodlar (processMNISTdata.m, d2gauss.m, data_aug.m)
- A satırı: orijinal örnekler, B satırı: yatay eksende eğme (horizontal shearing), C satırı: 35 derece döndürme, D ve E satırları: farklı derecelerde elastik deformasyon [*]



[*] Simard ve ark. 2003. Best practices for convolutional neural networks applied to visual document analysis. In ICDAR (Vol. 3, pp. 958-962)

Görüntüler için

- Rasgele kırpma
- Ayna yansıması
- Renk bilgilerinde değişim
- vb.



*Krizhevsky ve ark. 2012. Imagenet classification with deep convolutional neural networks.

*Ahmad, Jamil ve ark. 2017. Data augmentation-assisted deep learning of hand-drawn partially colored sketches for visual search.


[*https://arxiv.org/abs/1805.06201](https://arxiv.org/abs/1805.06201)

[*https://arxiv.org/abs/1805.09501](https://arxiv.org/abs/1805.09501)



Üretici Çekişmeli Ağlar (GAN)

- GAN'lar iki ağdan oluşmaktadır [*].
- Üretici ağ: rastgele bir gürültüden eğitim kümesine benzer örnekler üretmeye çalışır
- Ayırt edici ağ: gerçek eğitim örnekleriyle yapay örnekleri birbirinden ayırmayı öğrenir
- Bu iki ağ birbiriyle çekişme halindedir. Eğer üretici ağ çok başarılı olursa ayırt edici ağ doğal olarak başarısız olmaktadır.
- Bu yaklaşım özellikle görüntü veri kümeleri için çok gerçekçi yapay örneklerin üretimini sağlamaktadır.



İlk sıra: üretilenler, sonraki 5: en benzer eğitim örnekleri**



[*] Goodfellow, I. ve ark. 2014. Generative adversarial nets

[**] http://research.nvidia.com/sites/default/files/pubs/2017-10_Progressive-Growing-of/karras2018iclr-paper.pdf

Metin verileri için

- Eşanlamlı kelime / deyişler
 - Bizim oğlan komşu kızına abayı yakmış → Bizim oğlan komşu kızına aşık olmuş
 - Bir gün bana yaptıklarının acısını senden çıkaracağım → Senden intikamımı elbet alacağım
- Çeviri
 - orijinal örnek → başka bir dildeki karşılığı → yeni örnek
 - Sinema salonunda kırmızı ayakkabıları olan bir kadın gördüm → Sinema salonunda kırmızı ayakkabılı bir kadın gördüm.




Genel amaçlı veriler için

- Görüntülerde ve metinlerde etiketi değiştirmeyen dönüşümleri kullandık.
- Genel amaçlı (UCI vb.) veri kümeleri için ne yapılabilir?
 - Her sınıf için bir pdf tahmin etmek ve ondan yeni örnekler üretmek
 - SMOTE: az örnekli sınıftan bir örneğe en yakın k komşusunu bul. Bunlardan onunla aynı sınıfta olan birini seç. Bu ikisini birleştiren çizgi üzerinde yeni bir örnek üret.



Genel amaçlı veriler için



SMOTE*

SMOTE-IBF [**]: SMOTE özellikle karar sınırına yakın yerlerde yapay örnek ürettiği zaman sert sınıf geçişlerini zorlamaktadır. Bunu önlemek için SMOTE-IPF geliştirilmiştir.

Önce SMOTE ile örnekler üretilir.

Sonra hem orijinal hem de yeni üretilmiş örneklerden bazıları elenir.

Elemede veri kümesi k adet eşit parçaya bölünür. Her bir parça kullanılarak bir model eğitilir.

Ardından tüm modeller tüm veri kümesi üzerinde tahmin yürütür.

Her veri için k adet tahmin üretilir.

Bu tahminlerin tutarsız olduğu örnekler veri kümesinden çıkarılır.

Bu eleme ile karar sınırlarının daha yumuşak modellenebilir hale gelmesi amaçlanmaktadır.

[*] <https://jair.org/index.php/jair/article/view/10302>


[**] Sáez, J. A., ve ark. 2015. SMOTE-IPF: Addressing the noisy and borderline examples problem in imbalanced classification by a re-sampling method with filtering. Information Sciences

https://www.researchgate.net/figure/The-schematic-of-NRSBoundary-SMOTE-algorithm_fig1_287601878




Gürültü ile Düzenlileştirme

Regularization by adding noise



Gerçek lineer bir model.
Maviler eğitim örnekleri.
Kırmızı: 1. dereceden model
Sarı: 36. dereceden model




*Eğitim örnek sayısı artınca,
gerçeğe göre yüksek dereceden model de
iyi sonuçlar üretebiliyor, domain içinde 😊
*Ama yüksek boyutlu uzaylarda
yeterince çok örneğimiz olmaz.



Az örnek varken, örnekleri genişletelim

Kod noise_regularization.m



Gerçek: lineer bir model.

Mavi: eğitim örnekleri.

Kırmızı: Gauss gürültülü eğitim örnekleri

Sarı: 1. dereceden model

Yeşil: 36. dereceden model
(sadece eğitim örnekleri – 20 örnek)

Mor: 36. dereceden model (gürültü eklenmiş eğitim örnekleri – 120 örnek)

Yeni örnek üretimi:

Girişe Gauss gürültü ekle

Çıktışı aynı bırak

Test örnekleri üzerindeki hatalar:

1. dereceden: 0.1908

36. dereceden (gürültülü eğitim): 0.2404


36. dereceden (sadece eğitim): 5.5473e+03

Kompleks modellerin eğitiminde,
örneklere gürültü eklemek / örnekleri genişletmek
Modelin varyansını düşürüyor ☺



Temsilde noktadan dağılıma

- Bu süreci online olarak yapmak (gürültülü örnekleri tek seferde üretip eğitim kümesine katmak yerine her epoch da yeni örnekler üretmek) örnekleri tekil bir nokta değil de bir dağılım olarak temsil etmeye eş.
- Bunu kullanan ve genişleten yöntemler var: VAE* (örneklerin saklı uzaydaki temsillerinin hem ortalamalarını hem de varyanslarını öğreniyor).



Cümlelerin VAE ile temsili **




[*] <https://arxiv.org/abs/1312.6114>


[**] <https://arxiv.org/pdf/1511.06349.pdf>

Temsilde noktadan dağılıma Enterpolasyon

Rakamlar arası: $1 \rightarrow 9$, $6 \rightarrow 9$



Resimler arası *



Cümleler arası: **

the company said it will be n with the exception of the company
but the company said it will be n with the exception of the company ' s shares outstanding
but the company said that the company ' s n n and n n
but the company ' s n n in the past two years ago
but the company ' s n n in the past two years ago
but in the past few years ago that the company ' s n n
but in the past few years ago that they were n't disclosed
but in the past few years ago that they were n't disclosed
but in a statement that they were n't aware of the \$ n million in the past few weeks
but in a statement that they were n't paid by the end of the past few weeks




[*] <https://arxiv.org/pdf/1610.00291.pdf>

[**] <https://github.com/timbmg/Sentence-VAE>

ML algoritmalarını kandırmak (Adversarial Attacks)

- Kararlar makinelere bırakıldığı anda onları kandırma çalışmaları da başlar.
 - İstenmeyen e-postalar
- Derin öğrenme mimarilerinin başarılarının ardından ...
- En solda orijinal papağan. inception v3'e göre %97 olasılıkla "papağan". Bu resmin üzerine özel olarak hazırlanmış sağdaki gürültü eklenerek ortadaki resim oluşturulmuştur. Aynı inception mimarisine göre %99 olasılıkla "kitaplık".
- Daha önce gördüğümüz GAN'lar bu tür ataklara karşı dayanıklı mimariler üretmek için geliştirilmiştir.



ML algoritmalarını kandırmak

- Sadece derin öğrenme mimarileri tehdit altında değil.
- Bir Kaggle Yarışması* (3 görev)
 - Hedef belli atak (şu resme şunu dedirt)
 - Hedef belirsiz atak (kandır)
 - Savun
- Sadece tek bir piksel değişimiyle bile mümkün**



[*] <https://www.kaggle.com/c/nips-2017-defense-against-adversarial-attack>

[**] <https://arxiv.org/pdf/1710.08864.pdf>

Planlı öğrenme (Curriculum Learning)*

- Yeni örnekler geldiğinde eğitime baştan başlaması gerekmeyen öğrenciler için (online learning)
 - YSA, k-means, LVQ
- Örneklerin öğrenciye veriliş sırası önemli mi? / Bir müfredat oluşturmali mıyız?
- Evetse nasıl?
- Eldeki tüm veriler müfredata dahil edilmeli mi? (Aktif öğrenme sırasına karışmadan müfredatı kısıtlar)



[*] Bengio ve ark. 2009. Curriculum Learning

Planlı öğrenme

- İnsanlar için müfredat
 - İlköğretim, lise, üniversite, ...
 - Kolaydan zora ?
- Örneklerin kolaylık ölçütü?
 - Önceden belirlenip sabit kalsın
 - İnsan belirler
 - Bir algoritmanın sınıflara atama olasılıkları
 - Geometrik yaklaşımlar*
 - Öğrenme sırasında değişsin (self paced learning**)




[*] Ho T.K. ve ark. 2002. Complexity Measures of Supervised Classification Problems


[**] <http://papers.nips.cc/paper/5568-self-paced-learning-with-diversity>

Örneklerin zorlukları

- İnsan belirlesin*
 - Şekil sınıflandırma: ilk satır basit, ikinci satır zor
 - Metin veri kümelerinde:
 - Çokça görülen kelimeler kolay ...
 - Kısa cümleler kolay ...



Örneklerin zorluklarını ensemble belirlesin*



Average training and testing set errors at each epoch for ensemble based difficulty level determination on (a) breast-cancer, (b) colic, (c) credit-g, (d) waveform data sets.



[*] Mermer ve ark. 2017. Scalable Curriculum Learning for Artificial Neural Networks

NOVA Research Lab

Kolaydan zora / Zordan kolayla

- Sürpriz *

T-test Results ^a		Methods(X)					
		Classical	Classical (2n)	Curriculum (n)	Curriculum (2n)	Anti-curriculum (n)	Anti-curriculum (2n)
Methods(Y)	Classical	-	1/33/2	5/30/1	10/26/0	4/32/0	14/22/0
	Classical (2n)	2/33/1	-	6/29/1	11/25/0	6/30/0	14/22/0
	Curriculum (n)	1/30/5	1/29/6	-	8/28/0	4/31/1	11/25/0
	Curriculum (2n)	0/26/10	0/25/11	0/28/8	-	0/32/4	2/33/1
	Anti-curriculum (n)	0/32/4	0/30/6	1/31/4	4/32/0	-	4/32/0
	Anti-curriculum (2n)	0/22/14	0/22/14	0/25/11	1/33/2	0/32/4	-

^a. X(win)/tie/Y(win)



[*] Mermer ve ark. 2017. Scalable Curriculum Learning for Artificial Neural Networks

NOVA Research Lab

Hayat boyu öğrenme (Lifelong learning)

- Öğrenme sürecinin bitmediği
- Tüm eğitim verilerinin elde olmadığı / zaman içinde erişildiği
- Test örneklerinin sadece eğitim örneklerinin sınıflarından gelmediği (Open World)
- Önceki öğrenilenler nelerin / nasıl öğrenileceğine etken
- Endüstride daha yaygın



<https://www.cs.uic.edu/~liub/lifelong-learning.html>

[https://www.cs.uic.edu/~zchen/papers/ACL2015-Short-Zhiyuan\(Brett\)Chen.pdf](https://www.cs.uic.edu/~zchen/papers/ACL2015-Short-Zhiyuan(Brett)Chen.pdf)

<https://arxiv.org/abs/1906.01076>

Kendi kendine öğrenme (Self Supervised Learning)

- input-output ikililerinin insan etiketlemesi gerektirmeden hazırlanması
- Bu sayede çok büyük miktarda eğitim örneği
- Tahminler:
 - Bir sonraki kelime
 - Maskelenmiş kelime / resim parçası
 - 2 cümle ardışık mı
 - Bu cümlede değiştirilmiş kelime var mı?
 - Bu kelimelerin doğru sıralaması nedir?
- Büyük derlemler üzerinde bu gibi görevlerle eğitilen pre-trained /ön-eğitilmiş modeller, yeni bir eşiğin aşılmasını sağladı



[*] <https://ai.facebook.com/blog/self-supervised-learning-the-dark-matter-of-intelligence/>

Karşıtsal Öğrenme (Contrastive Learning)

- Bir tür self supervised
- Sınıfları bulma yerine örnek ikililerinin temsillerini birbirine yakın/uzak yapmayı öğrenir
- Bu 2 resim parçası aynı resimden mi yerine aynı resimden alınan parçaları yakınlaştır, farklı resimden olanları uzaklaştır
- Pozitif ve negatif örnekler
- İlk örneklerinden biri word2vec



[*] <https://arxiv.org/pdf/2002.05709.pdf>

[**] <https://lilianweng.github.io/posts/2021-05-31-contrastive/>

NOVA Research Lab

Karşıtsal Öğrenme (Contrastive Learning)





Figure 2. A simple framework for contrastive learning of visual representations. Two separate data augmentation operators are sampled from the same family of augmentations ($t \sim \mathcal{T}$ and $t' \sim \mathcal{T}$) and applied to each data example to obtain two correlated views. A base encoder network $f(\cdot)$ and a projection head $g(\cdot)$ are trained to maximize agreement using a contrastive loss. After training is completed, we throw away the projection head $g(\cdot)$ and use encoder $f(\cdot)$ and representation h for downstream tasks.

[*] <https://arxiv.org/pdf/2002.05709.pdf>

[*] <https://ai.googleblog.com/2020/04/advancing-self-supervised-and-semi.html>



Bağlam içi öğrenme (In context learning)

- Büyük dil modellerinde klasik ML yaklaşımı yerine bir alternatif. Model seçimi / eğitimi / hiperparametre opt. yok 😊
- Prompt'ta:
- *input1 – output1*
- *input2 – output2*
- *input3 – output3*
- *input4 – tahmin et*



[*] <http://ai.stanford.edu/blog/understanding-incontext/>