

Hata Analizi -2

Prof. Dr. M. Elif Karslıgil
Yıldız Teknik Üniversitesi
Computer Engineering Department
Intelligent Systems Lab.

Loss Function Nedir ?

Bir ML modelinin temel amacı, modelin hata payını en aza indirmektir.

- **Loss Function:** Tek bir veri örneği (örn. tek bir fotoğraf) için hesaplanan hatadır.
- **Cost Function:** Tüm eğitim setindeki (tüm veri) hataların ortalamasıdır.
- **Düşük Kayıp (Low Loss):** Modelin tahminleri gerçeğe çok yakındır.
- **Yüksek Kayıp (High Loss):** Modelin daha çok öğrenmesi gerekir.

Regresyon Problemleri için Loss Function

- **Mean Squared Error (MSE):** Büyük hatalar çok daha ağır cezalandırır.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Mean Absolute Error (MAE):** Outlier değerlere karşı daha dirençlidir.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Regresyon Problemleri için Loss Function

Bir ev fiyatı tahmin modeli 3 örnek için aşağıdaki tahminleri yapmıştır.

Ev No	Gerçek Fiyat (y)	Modelin Tahmini ($\hat{y}$)
1. Ev	100.000 TL	110.000 TL
2. Ev	200.000 TL	190.000 TL
3. Ev	150.000 TL	150.000 TL

MSE= 66.6


MAE= 6.6

Sınıflandırma için Loss Function

E-posta spam mi değil mi? Resimdeki hayvan nedir?

- **Binary Cross-Entropy (Log Loss):** Sadece iki seçenek olduğunda kullanılır. Modelin tahmini (olasılık değeri) doğrudan gerçek sınıfla karşılaştırılır.
- **Categorical Cross-Entropy:** İki den fazla sınıf olduğunda kullanılır.

Entropy



- Entropy S örneklerinin saflığını ölçer


İkili sınıflandırma:

- S : eğitim örnekleri
- p₊ pozitif örneklerin olasılığı
- p₋ negatif örneklerin olasılığı
- Entropy + veya – sınıları kodlamak için beklenen bit sayısı


$$\text{Entropy} = \sum_i -p_i \log_2 p_i$$

Entropy

$$\text{Entropy} = \sum_i -p_i \log_2 p_i$$



Minimum
impurity



- Bütün örnekler aynı sınıftaysa **Entropy = 0**
entropy = $-1 \log_2 1 = 0$

Maximum
impurity



- Örnekler yarı yarıya dağılmışsa **Entropy = 1**
entropy = $-0.5 \log_2 0.5 - 0.5 \log_2 0.5 = 1$

Cross Entropy Loss Function

- İki ayrı olasılık dağılımı arasındaki *cross entropy*, iki dağılımın ne kadar benzer olduğunu gösterir.
- Tahmin edilen çıkış ile beklenen çıkış arasındaki Cross Entropy


$$H(p, q) = - \sum_{x \in \text{classes}} p(x) \log q(x)$$

True probability distribution (one-shot) → $p(x)$


→ $q(x)$ Your model's predicted probability distribution

Cross Entropy Loss Function

- Eğitim sırasında ağırlıklar güncellenirken kullanılır
- Hesaplanan çıkış ile beklenen çıkış arasındaki mesafeyi hesaplar.
- Mükemmel modelde cross-entropy loss sıfır olur.
- CNN için CE hesabı:



Cross Entropy Loss Function



Dog

0.9

Cat

0.1

$$H(p, q) = - \sum_x p(x) \log q(x)$$

1
0

Softmax and Cross Entropy

- to train the network with backpropagation, we calculate the derivative of the loss :

The derivative of the loss with respect to the n-th node in the last hidden layer...

...is the n-th component of the network's prediction...

$$\frac{\partial L}{\partial l_n} = \hat{y}_n - y_n$$

...minus the n-th component of the label.

Binary Cross Entropy (Log Loss)

İki sınıflı bir problemde tek örnek için hata fonksiyonu:

$$Loss = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

Örnek: Bir e-postanın **Spam (1)** olup olmadığını tahmin ediyoruz.

- **Gerçek Durum:** E-posta Spam ($y=1$).
- **Modelin Tahmini:** %80 ihtimalle Spam ($y'=0.8$).

$$Loss = -[1 \cdot \log(0.8) + (1 - 1) \cdot \log(1 - 0.8)]$$

$$Loss = -[\log(0.8) + 0]$$

$$Loss \approx -(-0.097) = 0.097$$

Binary Cross Entropy (Log Loss)

- N adet örnek için toplam loss:

$$J(\theta) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Örnek	Gerçek Durum (y)	Model Tahmini ($\hat{y}$)	Loss Hesabı ($-[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$)
1. Veri	1 (Dolandırıcı)	0.90	$-\log(0.90) \approx \mathbf{0.105}$
2. Veri	0 (Normal)	0.10	$-\log(0.90) \approx \mathbf{0.105}$
3. Veri	1 (Dolandırıcı)	0.40	$-\log(0.40) \approx \mathbf{0.916}$

Toplam Kayıp: $0.105 + 0.105 + 0.916 = 1.126$

Toplam Maliyet(cost): $1.1126 / 3 = 0.375$

Binary Cross Entropy

Öğrenmede türev alan(gradyan tabanlı) yöntemler kullanır.

- **BCE kullanan temel ML yöntemleri:**

Lojistik Regresyon

Olasılıksal Destek Vektör Makineleri (Son katmanda lojistik reg. var)

XGBoost, LightGBM, CatBoost

- **BCE kullanan derin öğrenme tabanlı yöntemler:**

MLP (İkili sınıflandırma yapan sinir ağları modelleri)

CNN (Bu görüntüde kedi var mı?)

RNN/LSTM (Olumlu/Olumsuz Duygu analizi)

Autoencoder

GAN (Görüntü gerçek mi değil mi)

Categorical Cross Entropy

- Üç veya daha fazla sınıfın bulunduğu (Multi-class Classification) problemlerde kullanılır.
- Modelin çıktı olarak verdiği olasılık dağılımı ile verinin gerçek dağılımı arasındaki farkı (entropiyi) ölçer.
- CCE kullanabilmek için modelin son katmanında iki şart vardır:
 - 1.Nöron Sayısı: Sınıf sayısı kadar nöron olmalıdır.
 - 2.Aktivasyon: Çıktılar Softmax fonksiyonundan geçmelidir.

Categorical Cross Entropy

N adet veri örneği ve C adet sınıf için toplam maliyet (Cost):

$$J = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^C y_{i,j} \log(\hat{y}_{i,j})$$

- $y_{i,j}$: i. örneğin j. sınıfa ait olup olmadığı (1 veya 0 - One-Hot Encoding).
- $\hat{y}_{i,j}$: Modelin i. örneğin j. sınıfa ait olma olasılığı tahmini.

Categorical Cross Entropy

Senaryo: Bir "Köpek" fotoğrafı sisteme girdi.

1. **Gerçek Etiket (One-Hot Encoding):** Köpek sınıfı 2. sırada olsun. $y = [0, 1, 0]$
2. **Modelin Tahmini (Softmax Çıktısı):** Modelimiz şöyle bir tahminde bulundu: $\hat{y} = [0.1, 0.7, 0.2]$ (Kedi: %10, Köpek: %70, Kuş: %20)

Hesaplama:

Formüldeki iç toplamı ($\sum y \cdot \log(\hat{y})$) her sınıf için uygulayalım:

$$Loss = -((y_{kedi} \cdot \log(\hat{y}_{kedi})) + (y_{köpek} \cdot \log(\hat{y}_{köpek})) + (y_{kuş} \cdot \log(\hat{y}_{kuş})))$$

Değerleri yerine koyalım:

$$Loss = -((0 \cdot \log(0.1)) + (1 \cdot \log(0.7)) + (0 \cdot \log(0.2)))$$

Sihirli Nokta: Sıfır ile çarpılan tüm terimler yok olur! Geriye sadece gerçek sınıfa ait olan terim kalır:

$$Loss = -\log(0.7) \approx \mathbf{0.356}$$

Categorical Cross Entropy Kullanan Modeller

- **Gradyan Tabanlı Gelişmiş Ağaç Modelleri:**
 - XGBOOST, LIGHTGBM, CATBOOST
 - Gradient Boosting Machine
- **Derin Öğrenme ve Yapay Sinir Ağları:**
 - Multilayered Perceptron
 - Evrişimli Sinir Ağları (CNN)
 - Doğal Dil İşleme (NLP) Modelleri: Transformer, BERT

Loss Function Kullanımı - Özet

Problem Türü	Örnek Senaryo	Çıkış Katmanı (Nöron + Aktivasyon)	Kayıp Fonksiyonu (Loss)	Temel Mantık
Regresyon	Ev Fiyatı Tahmini	1 Nöron + Lineer (Aktivasyonsuz)	MSE (Mean Squared Error)	Tahmin ile gerçek arasındaki mesafenin karesini alır.
Regresyon	Aykırı Değerli Tahmin	1 Nöron + Lineer	MAE (Mean Absolute Error)	Hataların mutlak değerini alır, aykırı değerlere hoşgörülüdür.
İkili Sınıflandırma	Spam mı? (0 veya 1)	1 Nöron + Sigmoid	Binary Cross-Entropy	Doğru sınıfın olasılığını (0-1 arası) maksimize eder.
Çoklu Sınıflandırma	Kedi, Köpek, Kuş?	Sınıf Sayısı kadar Nöron + Softmax	Categorical Cross-Entropy	Sınıf olasılık dağılımları arasındaki farkı ölçer.