

Olasılıksal Robotik

Dr. Öğr. Üyesi Erkan Uslu

Parametrik Olmayan Filtreler

- Kalman ve türevleri parametrik ve fonksiyonel olarak tanımlanabilir posterior olasılık dağılımı (gauss dağılımı) varsayımına sahiptir
- Parametrik olmayan filtreler ise posterior olasılık dağılımını sonlu sayıda değer ile temsil eder
 - Durum uzayını ayrıştırarak → Histogram filtresi
 - Rastgele örnek üreterek → Parçacık filtresi
- Parametrik olmayan filtreler kompleks multimodal dağılımları temsil edebilir.

Parametrik Olmayan Filtreler

- Parametrik olmayan filtrelerin temsil kabiliyeti parametre sayısı ile doğru orantılıdır
- Posterior olasılık düşük bir karmaşıklığa sahipse (durum uzayı bir durum çevresinde odaklı ve düşük belirsizliğe sahipse) parametre sayısı az olur
- Kompleks posterior olasılıklar için ise parametre sayısı yüksek olur

Histogram Filtresi

- Durum uzayı sonlu sayıda bölgeye ayrıştırılır
- Durum uzayının yapısına göre
 - Sürekli durum uzayı → Histogram filtresi
 - Sonlu durum uzayı → Discrete Bayes filtresi


Discrete Bayes Filtresi

Algorithm 1: Ayırık (Discrete) Bayes Filtresi

input : $p_{k,t-1}, u_t, z_t$
output: $p_{k,t}$



- 1 forall k do
- 2 $\bar{p}_{k,t} = \sum_i p(X_t = x_k | X_{t-1} = x_i, u_t) p_{i,t-1};$
- 3 $p_{k,t} = \eta p(z_t | X_t = x_t) \bar{p}_{k,t};$
- 4 end

Histogram Filtresi



Histogram Filtresi


- Ayırıştırma yöntemleri
- Statik ayırıştırma:
 - 1B uzay için eşit aralık binler
 - 2B uzay için eşit aralık ızgaralar (grids)
- Dinamik ayırıştırma:
 - Yoğunluk ağaçları (density trees)
- Hibrid ayırıştırma:
 - Seçici güncelleme (selective updating)



Parçacık Filtresi – Particle Filter

- Posterior olasılık rastgele (random) olarak üretilmiş örnekler ile temsil edilir
- Karmaşık olasılık dağılımları temsil edilebilir
- Random değişkenlerin doğrusal olmayan dönüşümlerinde de iyi temsil kabiliyetine sahiptir

Parçacık Filtresi – Particle Filter



Parçacık Filtresi – Particle Filter

Algorithm 1: Parçacık (Particle) Filtresi

input : χ_{t-1}, u_t, z_t
output: χ_t

- 1 $\bar{\chi}_t = \chi_t = \emptyset;$
- 2 **for** $m \leftarrow 1$ **to** M **do**
- 3 *sample* $x_t^{[m]} \sim p(x_t | u_t, x_{t-1}^{[m]});$
- 4 $w_t^{[m]} = p(z_t | x_t^{[m]});$
- 5 $\bar{\chi}_t = \bar{\chi}_t \cup \langle x_t^{[m]}, w_t^{[m]} \rangle;$
- 6 **end**
- 7 **for** $m \leftarrow 1$ **to** M **do**
- 8 *sample* $x_t^{[i]} \sim w_t^{[i]};$
- 9 $\chi_t = \chi_t \cup x_t^{[i]};$
- 10 **end**

Parçacık Filtresi – Particle Filter

Algorithm 1: Parçacık (Particle) Filtresi

input : χ_{t-1}, u_t, z_t

output: χ_t

1 $\bar{\chi}_t = \chi_t = \emptyset$;

2 **for** $m \leftarrow 1$ **to** M **do**

3 *sample* $x_t^{[m]} \sim p(x_t | u_t, x_{t-1}^{[m]})$;

4 $w_t^{[m]} = p(z_t | x_t^{[m]})$;

5 $\bar{\chi}_t = \bar{\chi}_t \cup \langle x_t^{[m]}, w_t^{[m]} \rangle$;

6 **end**

7 **for** $m \leftarrow 1$ **to** M **do**

8 *sample* $x_t^{[i]} \sim w_t^{[i]}$;

9 $\chi_t = \chi_t \cup x_t^{[i]}$;

10 **end**

Resampling
Importance sampling




Resampling – Importance Sampling

$$\begin{aligned} E_f [x] &= \int f(x) x dx \\ &= \int \frac{f(x)}{g(x)} g(x) x dx \\ &= \int \omega(x) g(x) x dx \\ &= E_g [\omega(x) x] \end{aligned}$$


Resampling – Importance Sampling

- Elde etmek istenen temsil




Resampling – Importance Sampling

- Mevcut örnekler



Resampling – Importance Sampling

- Elde edilmek istenen temsile göre ağırlıklandırma




Ters Dönüşüm ile Örneklem

- P 1B olasılık dağılımına ilişkin PDF üzerinden integral alınarak CDF elde edilir
- Uniform dağılıma uygun bir x random sayısı üretilir
- $CDF^{-1}(x)$ P olasılık dağılımına göre üretilmiş bir random örnek olarak elde edilir

Ters Dönüşüm ile Örneklem (PDF)

- $p(a)=$


[0.028, 0.056,
0.110, 0.083,
0.042, 0.014,
0.014, 0.014,
0.028, 0.069,
0.125, 0.139,
0.125, 0.083,
0.056, 0.014]



Ters Dönüşüm ile Örneklem (CDF)

- $p(a)=$

[0.028, 0.056,
0.110, 0.083,
0.042, 0.014,
0.014, 0.014,
0.028, 0.069,
0.125, 0.139,
0.125, 0.083,
0.056, 0.014]



Ters Dönüşüm ile Örneklem

```
a=[0.028, 0.056, 0.110, 0.083, 0.042, 0.014, 0.014, 0.014, 0.028, 0.069, 0.125, 0.139,  
0.125, 0.083, 0.056, 0.014];
```

```
bar(a);
```

```
b(1)=a(1);
```

```
for i=2:16
```

```
    b(i)=b(i-1)+a(i);
```

```
endfor
```

```
figure
```

```
bar(b)
```

Ters Dönüşüm ile Örneklem

```
for i=1:100  
    c(i)=rand;  
endfor
```


```
for i=1:100  
    j=1;  
    while(c(i)>b(j) && j<=16)  
        j=j+1;  
    endwhile  
    s(i)=j;  
endfor
```

Ters Dönüşüm ile Örneklem



```
for i=1:16  
    bin(i)=sum(s==i);  
endfor  
  
figure  
bar(bin)
```

Ters Dönüşüm ile Örnekleme

of samples




Gerçek Dağılım – Üretilen Örnekler



Rejection Sampling

- Bilinen bir Q dağılımı kullanarak P dağılımı için örnekleme yapılmak istenirse
- c bir sabit olmak üzere $cQ \geq P$ olacak şekilde üstten limitleyen bir dağılım kullanılır
- Q 'dan bir x örnekleme yapılır
- $[0, cQ]$ aralığından u uniform bir örnek üretilir
- $u \leq P(x)$ ise örnekleme kabul edilir değilse reddedilir

Rejection Sampling



Normal Dağılım için Örnekleme – Box Muller Metodu

$$u_1, u_2 \sim Unif(0, 1)$$

$$R = \sqrt{-2 \log(u_1)}$$

$$\theta = 2\pi u_2$$

$$(x, y) = (R \cos \theta, R \sin \theta)$$

Normal Dağılım için Örneklememe – Central Limit Theorem


- Central Limit Theorem : bağımsız rassal değişkenler toplandığında bunların normalize edilmiş toplamaları normal dağılımı yakınsar
- Probabilistic robotics: b^2 varyanslı, 0 ortalamalı normal dağılımdan örneklememe için

$$\frac{1}{2} \cdot \sum_{i=1}^{12} rand(-b, b)$$

Üçgen Dağılım Örnekleme

- Üçgen dağılım normal dağılımın basitleştirilmiş bir versiyonu olarak düşünülebilir
- Probabilistic robotics: b^2 varyanslı, 0 ortalamalı üçgen dağılımdan örnekleme için

$$\frac{\sqrt{6}}{2} \cdot [rand(-b, b) + rand(-b, b)]$$



Örnek

- Mobil robot 2B uzayda sadece belirli bir doğrultuda uygulanan kontrol işareti L kadar hareket edebilmektedir. Robot bulunduğu konumun x eksenine izdüşümünü normal dağılıma uygun bir hata terimi ile ölçebilmektedir.
- Robota ilişkin durum tanımı aşağıda verilmiştir.

$$\mathbf{x} = \begin{pmatrix} x \\ y \\ \theta \end{pmatrix} \quad \begin{pmatrix} x' \\ y' \\ \theta' \end{pmatrix} = \begin{pmatrix} x + L \cos \theta \\ y + L \sin \theta \\ \theta \end{pmatrix} \quad \mathbf{z} = \mathbf{x}'$$



Örnek

- Robotun başlangıç durum inancı aşağıdaki gibidir



$$\mu_0 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \quad \Sigma_0 = \begin{pmatrix} 0.01 & 0 & 0 \\ 0 & 0.01 & 0 \\ 0 & 0 & 10000 \end{pmatrix}$$

- Başlangıç durumuna göre 1000 adet parçacığın dağılımını sağlayın
- Robotun L=2 birim ilerleme komutunu yürütmesi sonrası parçacıkların dağılımını sağlayın
- Robotun z=1.5 birim ölçüm alması sonucu parçacık dağılımını sağlayın


Örnek – Başlangıç konumu için parçacıklar



Örnek – L=2 ile hareket sonucu parçacıklar



Örnek – $z=1.5$ için parçacık ağırlıkları



Örnek – Resampling sonucu parçacıklar

