



BLM5116 – Veri Madenciliği ve Bilgi Keşfi

Prof. Dr. Songül VARL

Dönem Projesi

Pima Indians Diabetes Veri Seti Üzerinde Sınıflandırma Analizi

Hüsamettin IŞIKTAŞ

25501005

husamettin.isiktas@std.yildiz.edu.tr

1. Giriş ve Ön İnceleme:

Diyabet, dünya çapında milyonlarca insanı etkileyen ve erken teşhisin hayati önem taşıdığı kronik bir hastalıktır. Bu projenin temel amacı, Rastogi ve Bansal (2023) [1] tarafından yayınlanan makaledeki metodolojiyi incelemek, Pima Indians Diabetes veri seti [2] üzerinde bu çalışmayı tekrarlamak ve modern veri madenciliği teknikleri kullanarak sonuçları iyileştirmektir.


Proje gerçekleştirmeden önce bahsi geçen makale ayrıntılı bir şekilde incelenmiş ve makalede kullanılan yöntemlerle ilgili detaylar kesinleştirilmiştir. Makalede kullanılan Logistic Regression, SVM, Naïve Bayes ve Random Forest algoritmalarına ek olarak, güncel bir yaklaşım olan Yapay Sinir Ağları (MLP Classifier) da çalışmaya dahil edilmiştir.

Bu proje yeni ve Elsevier dergisinde yayınlanan bir proje olmasına rağmen bazı eksiklerinin olduğunu ilk aşamada gözlemledim. Bu eksiklerden başlıcası makalede confusion matrix olması gereken görsel corelation matrix'in olmasıydı. Kullanılan veri seti açık kaynaklı bir veri seti olmasına rağmen referans verilmemiş ve veri seti hakkındaki bilgiler doğru değildi. Örneğin veride erkek birey olmamasına rağmen erkek bireylerine olduğuna dair bir tablo gösterimi bulunuyordu. Veride yapılan ön işleme adımları ile ilgili ya da kullanılan modellerin parametreleri ile ilgili herhangi bir net bilgi yoktu. Dolayısıyla önce veriyi etraflıca inceleyerek işe başladım.

2. Veri Analizi ve Ön İşleme:


Bu adımda kullanılan veri seti ile ilgili incelemeler yapılmıştır. Kullanılan veri seti, 768 hasta ve 8 öznitelikten oluşmaktadır. Hedef değişken Outcome (0: Sağlıklı, 1: Diyabet) sınıfıdır. Veri seti üzerinde yapılan incelemelerde aşağıdaki sonuçlar elde edilmiştir.

- **Veri Seti Dengesizdir:** Aşağıdaki grafikte de net bir şekilde görülebileceği gibi hedef değişken dengeli dağılmamıştır. Dolayısıyla makalede de yapıldığı gibi accuracy metriği değil, precision ve sensitivity metrikleri daha önemli ölçüm metrikleri olarak seçilmelidir.




- **Eksik Veri ve Dağılım Bozukluğu:** Özelliklerin histogram dağılımları incelendiğinde bazı özelliklerde -özellikle glikoz, insülin ve deri kalınlığı özelliklerinde- 0 değerlerin bulunduğu gözlemlenmiştir. Veride boş veri bulunmasa da biyolojik olarak imkansız olan bu değerler eksik veri olarak değerlendirilmiştir. Ön işleme adımlarında veri doldurma işlemleri ile bu eksikler tamamlanmalıdır.

Özelliklerin Histogram Dağılımı




- **Korelasyon Matrisi:** Özellikler ve hedef değişken arasındaki ilişki incelenmiştir. Daha kolay incelemek adına korelasyon matrisi kullanılarak görselleştirilmiştir.



Yapılan incelemeler sonucunda veri setinde şu işlemler belirtilen sırada uygulanmıştır.

- Verideki imkansız değerleri NaN olarak işaretler
- Veri doldurma aşamasında mesafe bazlı bir teknik kullanıldığı için bütün verileri standart sapma normalizasyonu ile normalize et
- KNN Imputer yöntemi ile NaN olarak işaretlenen verileri doldur

Bu önışleme adımlarının ardından imkansız veri noktaları temizlenmiş ve eğitime hazır bir veri seti elde edilmiştir. Ayrıca toplam veri sayısı az olduğu için eğitim sırasında **K-fold Cross Validation** kullanılmıştır. Aşağıda elde edilen eğitim veri setinde doldurulan özellikler öncesi ve sonrası olarak sunulmuştur.



3. Model Eğitimi

Model eğitimi sırasında ve performans değerlendirmesi kısmında göz önünde bulundurulması gereken bir faktör bulunuyor. O da hedef değişken dengesizliği. Bu dengesizlik hem model performansı değerlendirmek için recall metriğini tercih etmemize hem de model eğitiminde sınıf ağırlıklandırması kullanmamıza sebep olmuştur.

Makalede kullanılan modeller **Logistic Regression, SVM, Random Forest ve Naive Bayes** algoritmalarıdır. Buna ek olarak derin öğrenme yöntemlerinden de **MLP** kullanılarak makalenin dışında farklı bir yöntem de denenmiştir. Makaledeki sonuçlar aşağıdaki tablodaki gibidir:

Model	Accuracy	Sensitivity (Recall)
Logistic Regression	82.46	68.23
Random Forest	81.81	68.88
Naive Bayes	79.22	64.44
SVM	79.22	59.99


Makalenin elde ettiği Accuracy ve Recall metriklerini geçmek amacıyla bir optimizasyon yapılmıştır: her algoritmanın kendi parametrelerinin grid search ile optimizasyonu. Bu optimizasyon işlemi yapılarak her model için uygun parametreler kullanılmış. Buna ek olarak model eğitim süreçlerinde destekleyen modeller için sınıf ağırlığı parametresi de sağlanmıştır.

4. Sonular ve Yorum:

5 modelin parametre optimizasyonu ardından eēitim sūreler yapılmıřtır. Elde edilen sonular referans makale ile karřılařtırılmıřtır.


İlk grafik incelendiēinde accuracy metriēinde makaleden daha az deēerler elde edilmiřtir. Ancak recall metriēinde  zellikle SVM modeli  nemli bir fark yaratmıřtır.

Makale ile Performans Karřılařtırması (5-Fold Cross Validation)




Eēittiēimiz modeller kendi aralarında ařaēıdaki grafikte karřılařtırılmıřtır. Bu grafik incelendiēinde SVM modeli recall metriēinde en iyi, Random Forest modeli accuracy metriēinde en iyi sonucu verdiēi g zlemlenmiřtir.

T m Modellerin Performans Karřılařtırması (5-Fold CV)



Karmařıklık matrisleri incelendiēinde b t n modellerin precision metriēinde zorlandıkları aıka g r lmektedir. Yani her model iin hasta olmayan birini hasta olarak etiketlemeye meyletmıř diyebiliriz.



Model	Accuracy (%)	Recall (%)	Precision (%)	F1-Score (%)
Random Forest	77.47 ± 2.53	72.03 ± 4.10	66.56 ± 4.02	69.07 ± 3.01
MLP Classifier	75.90 ± 4.47	67.90 ± 3.29	65.86 ± 8.12	66.52 ± 4.15
Logistic Regression	74.73 ± 4.76	73.49 ± 2.88	62.42 ± 7.31	67.23 ± 4.31
SVM	74.09 ± 2.33	76.89 ± 3.07	60.27 ± 3.26	67.47 ± 2.01
Naïve Bayes	73.82 ± 3.77	61.19 ± 3.06	63.60 ± 7.23	62.14 ± 3.83

Sonuçlar incelendiğinde aşağıdaki yorumlar yapılabilir:

- K-Fold CV yaklaşımı, model performansının farklı veri bölünmelerinde tutarlılığını gösterir ve overfitting riskini azaltır. Accuracy metrikleri açısından, makale sonuçları (79-82%) bizim ortalama sonuçlarımızdan (74-77%) yüksek görünse de, bu fark muhtemelen makalede kullanılan tek bir "şanslı" train-test split'ten kaynaklanmaktadır. Bizim sonuçlarımızda standart sapmalar (2-5%) gösteriyor ki, farklı veri bölünmelerinde performans değişkenlik gösterebilmektedir. **Recall (Sensitivity)** metrikleri açısından ise, bizim sonuçlarımız referans makaleye göre genel olarak daha yüksektir:
 - **SVM: 76.89%** (makale: 59.99%)
 - **Logistic Regression: 73.49%** (makale: 68.23%)
 - **Random Forest: 72.03%** (makale: 68.88%)

Bu iyileşme, uygulanan class weights ve KNN Imputer gibi gelişmiş ön işleme tekniklerinin etkisini göstermektedir.

- **SVM** modeli **76.89% $\pm$ 3.07%** recall değeri ile en yüksek sensitivity performansını göstermiştir. Bu, diyabet teşhisinde kritik olan "hasta olanları tespit etme" yeteneğinin SVM'de en güçlü olduğunu gösterir. SVM'in düşük standart sapması (3.07%) da modelin farklı veri bölünmelerinde tutarlı performans gösterdiğini işaret eder. İkinci en yüksek recall değeri **Logistic Regression (73.49% $\pm$ 2.88%)** ile elde edilmiştir. Bu model de düşük standart sapma ile güvenilir sonuçlar vermiştir.
- **Random Forest** modeli **69.07% $\pm$ 3.01% F1-Score** ile en dengeli performansı göstermiştir. F1-Score, precision ve recall'un harmonik ortalaması olduğu için, bu metrik modelin hem pozitif sınıfı doğru tespit etme (recall) hem de yanlış pozitif oranını düşük tutma (precision) konusunda en iyi dengeyi sağladığını gösterir. Random Forest aynı zamanda 77.47% $\pm$ 2.53% accuracy ile de en yüksek doğruluk oranına sahiptir. Bu modelin, ensemble yapısı sayesinde overfitting'e karşı daha dirençli olduğunu ve genelleştirme yeteneğinin güçlü olduğunu gösterir.

Son olarak bu çalışmada uygulanan metodolojik iyileştirmeler aşağıdaki gibi listelenebilir.

1. **5-Fold Stratified Cross Validation:** Tek bir train-test split yerine, tüm veri setinin farklı bölünmelerinde model performansının değerlendirilmesi
2. **KNN Imputer:** Eksik verilerin doldurulmasında basit ortalama yerine, veri yapısını koruyan K-Nearest Neighbors yöntemi
3. **Class Weights:** Dengesiz veri setinde recall'u iyileştirmek için sınıf ağırlıklarının kullanılması
4. **Pipeline Yaklaşımı:** Veri sızıntısını (data leakage) önlemek için preprocessing'in her fold için ayrı yapılması

Bu iyileştirmeler, modellerin gerçek dünya verilerinde daha güvenilir performans göstermesini sağlamıştır. Özellikle **standart sapma değerleri**, modellerin farklı veri bölünmelerinde ne kadar tutarlı olduğunu göstererek genelleştirme yeteneğini değerlendirmemize olanak tanımıştır.

5. Kaynakça:

[1] R. Rastogi and M. Bansal, "Diabetes prediction model using data mining techniques," Measurement: Sensors, vol. 25, art. no. 100605, 2023. DOI: <https://doi.org/10.1016/j.measen.2022.100605>.

[2] UCI Machine Learning Repository, "Pima Indians Diabetes Database," Kaggle. [Online]. Erişim Adresi: <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>. [Erişim Tarihi: 13 Aralık 2025].