

Web Veri Madenciliği — Kapsamlı Sınav Hazırlık Raporu

Yıldız Teknik Üniversitesi — Bilgisayar Mühendisliği

Haziran 2026

İçindekiler

1	Giriş	2
2	Birliktelik Kuralı Madenciliği ve Market Sepeti Modeli	2
2.1	Temel Veri Modeli	2
2.2	Birliktelik Kurallarının Tanımı	2
2.3	Kural Güç Ölçütleri: Destek ve Güven	2
2.4	Pratik Örnekler	3
2.4.1	Örnek 1	3
2.4.2	Örnek 2	3
3	Apriori Algoritması ve Varyasyonları	3
3.1	Apriori Özelliği (Aşağı Doğru Kapanış Özelliği)	3
3.2	Sık Öğe Kümelerinin Seviye Tabanlı Çıkarımı	3
3.3	Aday Üretim Fonksiyonu (candidate-gen)	4
3.4	Sık Kümelerden Kuralların Üretilmesi	4
3.5	Ana Bellek Hesaplama Modelleri	4
3.6	Apriori İyileştirmeleri: PCY, Multistage ve Multihash	4
3.6.1	PCY (Park-Chen-Yu)	4
3.6.2	Multistage	4
3.6.3	Multihash	4
4	Gelişmiş Veri Formatları ve CAR Modeli	4
4.1	Veri Formatlarının Dönüşümü	4
4.2	Sınıf Birliktelik Kuralları (CAR)	4
5	Sıralı Örüntü Madenciliği (Sequential Pattern Mining)	5
5.1	Temel Kavramlar	5
5.2	GSP (Generalized Sequential Pattern) Algoritması	5
6	Bilgi Erişimi (IR) ve Web Araması	5
6.1	DIKW Hiyerarşisi	5
6.2	IR vs Veritabanı Erişimi	5
6.3	Temel IR Modelleri	5
6.3.1	Boolean Model	5
6.3.2	Vektör Uzay Modeli (TF-IDF)	5
6.3.3	Okapi BM25	6
6.3.4	Sorgu Genişletme (Rocchio)	6
6.4	Metin Ön İşleme	6

6.5	Değerlendirme: Precision & Recall	6
6.6	Ters Dizin (Inverted Index)	6
7	Sosyal Ağ Analizi ve Merkezilik Ölçütleri	6
7.1	Merkezilik Ölçütleri (Centrality)	6
7.1.1	Derece Merkeziliği (Degree)	6
7.1.2	Yakınlık Merkeziliği (Closeness)	6
7.1.3	Arasındalık Merkeziliği (Betweenness)	6
7.2	Saygınlık Ölçütleri (Prestige)	7
7.3	Atıf Analizi	7
8	PageRank ve Link Analizi (Google Formülasyonu)	7
8.1	Temel Formülasyon ve Akış Denklemleri	7
8.2	Özvektör Formülasyonu ve Power Iteration	7
8.3	Graf Yapısı Kaynaklı Problemler	7
8.3.1	Spider Traps (Örümcek Tuzakları)	7
8.3.2	Dead Ends (Ölü Uçlar)	7
8.4	Google Çözümü: Rastgele Işınlanma (Random Teleports)	7
8.5	Markov Zinciri Analjisi	8
9	Akış Madenciliği ve Bloom Filtreleri	8
9.1	Motivasyon	8
9.2	Çalışma Mekanizması	8
9.3	Olasılık Analizi: Dart Atma Modeli	8
9.4	Sayısal Örnek	8
10	Web Crawler (Örümcek) Mimarisi	8
10.1	Crawler Taksonomisi	8
10.2	Temel Mimari	9
10.3	Uygulama Zorlukları	9
10.4	Eşzamanlılık ve Ölçeklenebilirlik	9
10.5	Güncellik (Freshness) Politikası	9
10.6	Gelişmiş Odaklı Tarama	9
11	Web Kullanım Madenciliği (Web Usage Mining)	9
11.1	Süreç Aşamaları	9
11.2	Kullanıcı Tanımlama Yöntemleri	10
11.3	Oturumlaştırma (Sessionization)	10
11.4	Önbellek Etkisi ve Yol Tamamlama	10
11.5	E-Ticaret Entegrasyonu	10
11.6	Veri Madenciliği Teknikleri	10
12	Tavsiye Sistemleri (Recommender Systems)	10
12.1	Uzun Kuyruk (Long Tail) Fenomeni	10
12.2	Formal Model	11
12.3	İçerik Tabanlı Filtreleme	11
12.4	İşbirlikçi Filtreleme (Collaborative Filtering)	11
12.4.1	Kullanıcı-Kullanıcı Benzerlik Metrikleri	11
12.4.2	Rating Tahminleme	11
12.4.3	Ürün-Ürün (Item-Item) Modeli — Sayısal Örnek	11
12.5	Performans Değerlendirme	11
12.5.1	RMSE	11
12.5.2	Precision at Top-K	12

1 Giriş

Bu rapor, birliktelik kuralı madenciliği (association rule mining), sıralı örüntü madenciliği (sequential pattern mining), bilgi erişimi (information retrieval), web araması, sosyal ağ analizi (social network analysis), web crawler mimarisi, web kullanım madenciliği ve tavsiye sistemleri konularını kapsayan akademik ders materyallerinin detaylı bir derlemesidir. Sınav hazırlığı amacıyla hazırlanan bu belgede, tüm temel tanımlar, matematiksel formülasyonlar, algoritma adımları ve pratik örnekler eksiksiz bir şekilde sunulmuştur.

2 Birliktelik Kuralı Madenciliği ve Market Sepeti Modeli

Birliktelik kuralı madenciliği ilk olarak 1993 yılında Agrawal ve arkadaşları tarafından önerilmiştir. Database ve veri madenciliği toplulukları tarafından yaygın olarak çalışılan bu model, başlangıçta müşterilerin satın alma alışkanlıkları arasındaki ilişkileri ortaya çıkarmak amacıyla **Market Sepeti Analizi (Market Basket Analysis)** için kullanılmıştır.

2.1 Temel Veri Modeli

Birliktelik kuralları çıkarılırken verilerin kategorik olduğu varsayılır; nümerik veriler için doğrudan çalışan iyi bir algoritma bulunmamaktadır. Veri modeli şu şekilde tanımlanır:

- $I = \{i_1, i_2, \dots, i_m\}$ mağazada satılan tüm öğelerin (items) kümesidir.
- İşlem (Transaction) t : Müşterinin bir alışverişte sepetine eklediği öğelerin kümesidir ve $t \subseteq I$ şartını sağlar. Her işlemin benzersiz bir işlem kimliği (TID - Transaction ID) bulunabilir.
- İşlem Veritabanı $T = \{t_1, t_2, \dots, t_n\}$ sisteme kayıtlı tüm işlemlerin kümesidir.

2.2 Birliktelik Kurallarının Tanımı

Bir t işlemi, eğer $X \subseteq t$ ise X öge kümesini (itemset) içeriyor denir. Bir birliktelik kuralı, şu formda bir çıkarımdır:

$$X \rightarrow Y, \quad \text{burada } X, Y \subset I \text{ ve } X \cap Y = \emptyset \quad (1)$$

Burada X kuralın öncülü (antecedent/condition), Y ise ardılıdır (consequent). İçinde k adet öge barındıran kümeler k -öge kümesi (k -itemset) denir.

2.3 Kural Güç Ölçütleri: Destek ve Güven

Bir kuralın anlamlı ve güçlü olup olmadığını belirlemek için iki temel ölçüt kullanılır:

1. **Destek (Support - sup):** $X \rightarrow Y$ kuralının işlem veritabanı T içindeki desteği, veritabanındaki tüm işlemler içinde hem X hem de Y öğelerini birlikte içeren işlemlerin oranıdır. Olasılıksal olarak $Sup = Pr(X \cup Y)$ şeklinde ifade edilir.
2. **Güven (Confidence - conf):** $X \rightarrow Y$ kuralının güveni, X ögesini içeren işlemler içinden yüzde kaçının Y ögesini de içerdiğini gösterir. Koşullu olasılık olarak $conf = Pr(Y|X)$ şeklinde tanımlanır.

Matematiksel olarak:

$$\text{support} = \frac{(X \cup Y).\text{count}}{n} \quad (2)$$

$$\text{confidence} = \frac{(X \cup Y).\text{count}}{X.\text{count}} \quad (3)$$

Hedef: Kullanıcı tarafından belirlenen minimum destek (*minsup*) ve minimum güven (*minconf*) eşik değerlerini sağlayan tüm kuralları bulmaktır.

2.4 Pratik Örnekler

2.4.1 Örnek 1

Aşağıdaki işlem veritabanını ele alalım:

TID	Satın Alınan Öğeler
10	A, B, D
20	A, C, D
30	A, D, E
40	B, E, F
50	B, C, D, E, F

Eşik değerleri minsup = 50% ve minconf = 50% olarak belirlensin. Toplam işlem sayısı $n = 5$ olduğundan, bir öğe kümesinin sık sayılabilmesi için en az $5 \times 0.5 = 2.5 \rightarrow 3$ işlemde geçmesi gerekir.

- Sık Öğe Kümeleri ve Sayıları: $\{A : 3, B : 3, D : 4, E : 3, \{A, D\} : 3\}$
- $A \rightarrow D$: support = $3/5 = 60\%$, confidence = $3/3 = 100\%$
- $D \rightarrow A$: support = $3/5 = 60\%$, confidence = $3/4 = 75\%$

2.4.2 Örnek 2

7 işlemden oluşan bir veritabanında $\{Chicken, Clothes, Milk\}$ kümesinin destek sayısı 3 olsun (sup = 3/7). Bu sık kümeden üretilen kurallar:

- $Clothes \rightarrow Milk, Chicken$ (sup = 3/7, $Clothes.count = 3$ ise conf = 100%)
- $Clothes, Chicken \rightarrow Milk$ (sup = 3/7, conf = 100%)

3 Apriori Algoritması ve Varyasyonları

En bilinen algoritma **Apriori** algoritmasıdır ve iki ana adımdan oluşur:

1. Minimum desteğe sahip tüm sık öğe kümelerinin (frequent itemsets) bulunması.
2. Bu sık kümelerden minimum güveni sağlayan birliktelik kurallarının üretilmesi.

3.1 Apriori Özelliği (Aşağı Doğru Kapanış Özelliği)

"Eğer bir öğe kümesi sık ise, onun tüm alt kümeleri de sık olmak zorundadır."

Bu ilkenin karşıt tersi: Eğer bir i öğesi en az s kadar sepet içerisinde yer almıyorsa, i öğesini içeren hiçbir çift veya daha büyük küme sık olamaz.

3.2 Sık Öğe Kümelerinin Seviye Tabanlı Çıkarımı

Apriori, seviye tabanlı (level-wise) iteratif bir arama yapar. Önce 1 boyutlu sık kümeler (F_1), sonra bunlardan adaylar üretilerek ilerlenir.

3.3 Aday Üretim Fonksiyonu (candidate-gen)

`candidate-gen`(F_{k-1}) fonksiyonu iki adımdan oluşur:

1. **Birleştirme (Join Step):** F_{k-1} kümesindeki iki sık küme, ilk $k - 2$ öğeleri aynı ve son öğeleri sözlüksel sırada $f_1.i_{k-1} < f_2.i_{k-1}$ olacak şekilde birleştirilir.
2. **Budama (Prune Step):** Oluşturulan c adayının tüm $k - 1$ boyutlu alt kümeleri kontrol edilir. Herhangi biri F_{k-1} içinde yoksa c elenir.

Aday Üretim Örneği: $F_3 = \{\{1, 2, 3\}, \{1, 2, 4\}, \{1, 3, 4\}, \{1, 3, 5\}, \{2, 3, 4\}\}$ olsun.

- **Join:** $\{1, 2, 3\} \cup \{1, 2, 4\} = \{1, 2, 3, 4\}$, $\{1, 3, 4\} \cup \{1, 3, 5\} = \{1, 3, 4, 5\}$
- **Prune:** $\{1, 3, 4, 5\}$ adayının alt kümesi $\{1, 4, 5\} \notin F_3$ olduğu için budanır. $C_4 = \{\{1, 2, 3, 4\}\}$ kalır.

3.4 Sık Kümelerden Kuralların Üretilmesi

Her bir sık X öğe kümesi için, onun boş olmayan her öz alt kümesi A seçilir. $B = X - A$ olsun:

$$\text{Confidence}(A \rightarrow B) = \frac{\text{support}(X)}{\text{support}(A)} \geq \text{minconf} \quad (4)$$

3.5 Ana Bellek Hesaplama Modelleri

1. **Üçgensel Matris Yaklaşımı:** Çift başına 4 bayt, toplam $\approx 2n^2$ bayt.
2. **Tablosal Yöntem (Triples):** Yapı başına 12 bayt, sadece count > 0 olan çiftler için.

3.6 Apriori İyileştirmeleri: PCY, Multistage ve Multihash

3.6.1 PCY (Park-Chen-Yu)

İlk geçişte boş belleği hash tablosu olarak kullanır. Sık olmayan kovalar bitmap ile elenir.

3.6.2 Multistage

PCY'ye ek geçiş ekleyerek ikinci bir hash ile budama yapar.

3.6.3 Multihash

İlk geçişte birden fazla bağımsız hash tablosu kullanır.

4 Gelişmiş Veri Formatları ve CAR Modeli

4.1 Veri Formatlarının Dönüşümü

Tablo formatındaki veriler, her nitelik-değer çifti benzersiz bir öğe olarak işlem formatına dönüştürülür.

4.2 Sınıf Birliktelik Kuralları (CAR)

$$X \rightarrow y, \quad \text{burada } X \subseteq I \text{ ve } y \in Y \quad (5)$$

CAR madenciliği normal kuralların aksine **doğrudan tek adımda** yapılabilir. Temel işlem, *minsup* üzerindeki tüm **kural-öğelerini (ruleitems)** bulmaktır.

5 Sıralı Örüntü Madenciliği (Sequential Pattern Mining)

5.1 Temel Kavramlar

- **Dizi (Sequence) s :** Öğe kümelerinin sıralı listesi. $\langle a_1 a_2 \dots a_r \rangle$.
- **Boyut (Size):** Dizideki eleman sayısı.
- **Uzunluk (Length):** Dizideki toplam tekil öğe sayısı (k -dizi).
- **Alt Dizi:** $a_i \subseteq b_{j_i}$ kapsaması ve $j_1 < j_2 < \dots < j_r$ indis sıralaması.

5.2 GSP (Generalized Sequential Pattern) Algoritması

Apriori benzeri seviyeli yaklaşım. İlk geçişte sık 1-diziler, ardından aday üretim-budama döngüsü.

6 Bilgi Erişimi (IR) ve Web Araması

6.1 DIKW Hiyerarşisi

- **Veri (Data):** Ham web sayfaları.
- **Bilgi (Information):** Sorgu sonucu dönen liste.
- **Bilgi birikimi (Knowledge):** Kullanıcının sonuçları anlamlandırması.
- **Bilgelik (Wisdom):** Kullanıcı eylemlerinin sentezi.

6.2 IR vs Veritabanı Erişimi

Bilgi Erişimi (IR)	Veritabanı Erişimi
İlgili tüm nesneleri getirir, sıralı liste döner.	Tam eşleşme, kesin sonuç kümesi.

6.3 Temel IR Modelleri

6.3.1 Boolean Model

İkili ağırlıklar ($w_{ij} \in \{0, 1\}$), tam eşleşme. Terim frekanslarını dikkate almaz.

6.3.2 Vektör Uzay Modeli (TF-IDF)

$$tf_{ij} = \frac{f_{ij}}{\max_k \{f_{1j}, f_{2j}, \dots, f_{|V|j}\}} \quad (6)$$

$$idf_i = \log \frac{N}{df_i} \quad (7)$$

$$\text{cosine}(d_j, q) = \frac{\sum w_{ij} \times w_{iq}}{\sqrt{\sum w_{ij}^2} \times \sqrt{\sum w_{iq}^2}} \quad (8)$$

6.3.3 Okapi BM25

$$\text{okapi}(d_j, q) = \sum_{t_i \in q \cap d_j} \ln \frac{N - df_i + 0.5}{df_i + 0.5} \times \frac{(k_1 + 1)f_{ij}}{k_1(1 - b + b \frac{dl_j}{\text{avdl}}) + f_{ij}} \times \frac{(k_2 + 1)f_{iq}}{k_2 + f_{iq}} \quad (9)$$

6.3.4 Sorgu Genişletme (Rocchio)

$$q_e = \alpha q + \frac{\beta}{|D_r|} \sum_{d_r \in D_r} d_r - \frac{\gamma}{|D_{ir}|} \sum_{d_{ir} \in D_{ir}} d_{ir} \quad (10)$$

6.4 Metin Ön İşleme

- **Stopwords Removal:** İndeks boyutunu %20-%30 azaltır.
- **Stemming:** Duyarlılığı (recall) artırır, indeks boyutunu %40-%50 küçültür.

6.5 Değerlendirme: Precision & Recall

$$\text{Precision} = \frac{|A \cap B|}{|B|}, \quad \text{Recall} = \frac{|A \cap B|}{|A|} \quad (11)$$

6.6 Ters Dizin (Inverted Index)

Her kelimeyi, geçtiği dokümanların listesine bağlayan veri yapısı. Gelişmiş versiyonlarda terim frekansı ve pozisyonlar da saklanır.

7 Sosyal Ağ Analizi ve Merkezilik Ölçütleri

7.1 Merkezilik Ölçütleri (Centrality)

7.1.1 Derece Merkeziliği (Degree)

$$C_D(i) = \frac{d(i)}{n - 1}, \quad C'_D(i) = \frac{d_o(i)}{n - 1} \quad (12)$$

Merkezileşme (Centralization):

$$C_D = \frac{\sum_{i=1}^n [C_D(n^*) - C_D(i)]}{(n - 1)(n - 2)} \quad (13)$$

7.1.2 Yakınlık Merkeziliği (Closeness)

$$C_C(i) = \frac{n - 1}{\sum_{j=1}^n d(i, j)} \quad (14)$$

7.1.3 Arasındalık Merkeziliği (Betweenness)

$$C_\beta(i) = \frac{2 \sum_{j < k} \frac{p_{jk}(i)}{p_{jk}}}{(n - 1)(n - 2)} \quad (15)$$

7.2 Saygınlık Ölçütleri (Prestige)

- **Proximity Prestige:** $P_p(i) = \frac{|I_i|^2}{(n-1) \sum_{j \in I_i} d(j,i)}$
- **Rank Prestige:** $P = A^T P$ (özvektör problemi)

7.3 Atıf Analizi

- **Co-citation:** $C = L^T L$
- **Bibliographic Coupling:** $B = L L^T$

8 PageRank ve Link Analizi (Google Formülasyonu)

8.1 Temel Formülasyon ve Akış Denklemleri

Bir j sayfasının PageRank skoru (r_j):

$$r_j^{(t+1)} = \sum_{i \rightarrow j} \frac{r_i^{(t)}}{d_i} \quad (16)$$

Matris formunda: $r = M \cdot r$. M sütun-stokastik matristir, $M_{ji} = \frac{1}{d_i}$.

8.2 Özvektör Formülasyonu ve Power Iteration

Rank vektörü r , M 'in $\lambda = 1$ özdeğerine karşılık gelen birincil özvektörüdür.

1. Başlangıç: $r_j^{(0)} = \frac{1}{n}$
2. İterasyon: $r^{(t+1)} = M \cdot r^{(t)}$
3. Yakınsayana kadar tekrarla.

8.3 Graf Yapısı Kaynaklı Problemler

8.3.1 Spider Traps (Örümcek Tuzakları)

Tüm dış bağlantıları sadece grup içine olan sayfalar. Tüm PageRank skoru bu grupta soğurulur, diğer sayfalar sıfırlanır.

8.3.2 Dead Ends (Ölü Uçlar)

Hiç dış bağlantısı olmayan sayfalar. Toplam önem skoru dışarı sızar (importance leak), tüm vektör sıfıra yakınsar.

8.4 Google Çözümü: Rastgele Işınlanma (Random Teleports)

- β olasılıkla link takip eder.
- $1 - \beta$ olasılıkla rastgele sayfaya ışınlanır ($\beta \approx 0.8 - 0.9$).

$$r_j = \sum_{i \rightarrow j} \beta \frac{r_i}{d_i} + (1 - \beta) \frac{1}{n} \quad (17)$$

$$A = \beta M + (1 - \beta) \frac{1}{n} e \cdot e^T \quad (18)$$

8.5 Markov Zinciri Analjisi

Yakınsama için geiş matrisi řu üç řartı saėlamalıdır:

1. **Stochastic:** Her sütun toplamı 1.
2. **Aperiodic:** Periyot $k > 1$ olmamalı (ışınlanma ile kırılır).
3. **Irreducible:** Her durumdan her duruma geiş olasılığı > 0 (tam ışınlanma matrisi ile saėlanır).

9 Akış Madenciliėi ve Bloom Filtreleri

9.1 Motivasyon

Web crawler, keřfettiėi URL'lerden daha önce indirilmiş olanları ayıklamak zorundadır. Milyarlarca URL'i RAM'de tutmak imkansız olduėundan Bloom Filtresi kullanılır.

9.2 Çalışma Mekanizması

N bitlik dizi + k adet baėımsız hash fonksiyonu.

- **Ekleme:** $h(x)$ konumlarındaki tüm bitler 1 yapılır.
- **Sorgulama:** En az bir bit 0 ise kesinlikle eklenmemiřtir (False Negative imkansız). Tüm bitler 1 ise "görüldü" denir ama False Positive riski vardır.

9.3 Olasılık Analizi: Dart Atma Modeli

t hedef, d dart:

$$P(\text{False Positive}) = \left(1 - e^{-\frac{d}{t}}\right)^k \quad (19)$$

9.4 Sayısal Örnek

$t = 10^9$, $k = 5$, 10^8 eleman:

- $d = 5 \times 10^8$
- 0 bit oranı: $e^{-0.5} \approx 0.607$
- 1 bit yoğunluėu: 0.393
- False Positive: $(0.393)^5 \approx 0.94\%$

10 Web Crawler (Örümcek) Mimarisi

10.1 Crawler Taksonomisi

1. **Universal Crawlers:** Tüm webi tarar (Google, Bing).
2. **Preferential Crawlers:** Önem deėerine göre öncelikli tarama.
 - **Focused:** Etiketli veriyle eğitilmiş sınıflandırıcı.
 - **Topical:** Sadece anahtar kelime benzerliėi ile.

10.2 Temel Mimari

Seed URLs → Frontier → Fetch → Extract URLs → Repository

- **BFS:** Queue (FIFO) — en kısa yol, kaliteli kök sayfalara yakın kalır.
- **DFS:** Stack (LIFO) — siber uzayda kaybolma riski.

10.3 Uygulama Zorlukları

- **Stop Words:** Negatif sözlük ile eleme.
- **Stemming:** Porter Stemmer, Snowball. İndeks boyutunu %30-50 küçültür.
- **URL Canonicalization:** Büyük-küçük harf, default port (:80), fragment temizleme, /.../ eleme.
- **CGI Spider Traps:** URL uzunluğu kontrolü, domain başına URL sayısı izleme.
- **Sayfa Deposu:** MD5 hash ile isimlendirme, Berkeley DB ile indeksleme.

10.4 Eşzamanlılık ve Ölçeklenebilirlik

Asenkron soketler (non-blocking I/O), UDP tabanlı DNS ön belleği, paralel kuyruklar, tarama makine çiftlikleri.

10.5 Güncellik (Freshness) Politikası

Brewington & Cybenko, Cho, Garcia-Molina & Page algoritmaları. Değişim derecesi (degree of change), değişim sıklığından daha iyi tahmincidir.

10.6 Gelişmiş Odaklı Tarama

- **Best-N-First:** Her N sayfada bir lazy sort.
- **Shark Search:** Sayfa benzerliği + anchor text + ebeveyn kalitesi.
- **Co-citation (Hub Locality):** Ortak sayfaları işaret eden sayfalar.
- **Co-reference (Authority Locality):** Aynı otoriteye link veren sayfalar.

11 Web Kullanım Madenciliği (Web Usage Mining)

11.1 Süreç Aşamaları

1. **Data Preprocessing:** Ham log temizleme ve dönüşüm.
2. **Pattern Discovery:** Madencilik algoritmaları.
3. **Pattern Analysis:** Kalıpların filtrelenmesi ve yorumlanması.

11.2 Kullanıcı Tanımlama Yöntemleri

Yöntem	Açıklama	Gizlilik	Avantaj	Dezavantaj
IP + Agent	IP + Browser Agent	Düşük	Her zaman hazır	Rotating IP'lerde çok
Embedded ID	Link sonuna session ID	Düşük-Orta	IP'den bağımsız	Geri gelen kullanıcıyı
Registration	Login	Orta	Bireyi takip eder	Kayıt istemeyebilir
Cookie	İstemciye kimlik dosyası	Orta-Yüksek	Tekrar ziyaretleri yakalar	Kapatılabilir
Software Agent	Tarayıcı eklentisi	Yüksek	En kesin veri	Reddedilme oranı yük

11.3 Oturumlaştırma (Sessionization)

1. Zaman Odaklı:

- h1: Toplam oturum süresi ≤ 30 dk.
- h2: Sayfa kalma süresi ≤ 10 dk.

2. Gezinim Odaklı:

- Yeni sayfa, önceki sayfalardan referrer ile doğrulanmalı. Referans boşsa ve < 10 sn ise aynı oturum.

11.4 Önbellek Etkisi ve Yol Tamamlama

Geri butonu cache'den okunduğu için sunucu loglarında kayıp oluşur. Yol tamamlama, site link yapısı ve Referrer alanları ile kayıp geçişleri yeniden inşa eder.

11.5 E-Ticaret Entegrasyonu

- **Ürün Olayları:** View, Click-through, Sepet değişiklikleri, Satın alma.
- **Sayfa Tipleri:** Head (kök), Media (uzun kalma süresi), Navigation (çok link, kısa süre), Look-up/Data Entry (form içerir).

11.6 Veri Madenciliği Teknikleri

- **Frequent Itemsets:** Hangi sayfalar birlikte ziyaret ediliyor?
- **Association Rules:** Sayfalar arası yönlü ilişkiler.
- **Sequential Patterns:** Zamansal sıralı kalıplar.
- **Clustering/Classification:** Davranışsal segmentasyon.

12 Tavsiye Sistemleri (Recommender Systems)

12.1 Uzun Kuyruk (Long Tail) Fenomeni

Fiziksel rafta sadece hit ürünler sergilenir. Web'de dağıtım maliyeti sıfıra yakın olduğu için niş ürünler de satılabilir — bu bolluk tavsiye motorlarına ihtiyaç doğurur.

12.2 Formal Model

- C : Kullanıcılar, S : Ürünler.
- $u : C \times S \rightarrow R$ fayda fonksiyonu.
- **Explicit**: Doğrudan puanlama (az kullanıcı yapar).
- **Implicit**: Hareketlerden çıkarım (satın alma= beğeni; düşük puan tespiti zor).
- **Cold Start**: Yeni kullanıcı/ürün için veri yokluğu.

12.3 İçerik Tabanlı Filtreleme

Kullanıcının geçmişte beğendiği ürünlere benzer ürünler önerme.

$$TF_{ij} = \frac{f_{ij}}{\max_k f_{kj}}, \quad IDF_i = \log \frac{N}{n_i}, \quad W_{ij} = TF_{ij} \times IDF_i \quad (20)$$

$$u(x, i) = \cos(\theta) = \frac{x \cdot i}{|x||i|} \quad (21)$$

- **+**: Diğer kullanıcılara ihtiyaç duymaz, niş zevklere uygun, yeni ürünleri önerebilir.
- **-**: Görsel/video öznitelik çıkarımı zor, aşırı uzmanlaşma (overspecialization), yeni kullanıcı cold-start.

12.4 İşbirlikçi Filtreleme (Collaborative Filtering)

12.4.1 Kullanıcı-Kullanıcı Benzerlik Metrikleri

1. **Jaccard**: $\text{sim}(A, B) = \frac{|r_A \cap r_B|}{|r_A \cup r_B|}$ (puan değerlerini yok sayar).
2. **Cosine**: Eksik puanları 0 kabul eder, hatalı.
3. **Centered Cosine (Pearson)**: Satır bazında ortalama çıkarılır, eksikler otomatik 0 olur.

12.4.2 Rating Tahminleme

$$r_{xi} = \frac{\sum_{y \in N} s_{xy} r_{yi}}{\sum_{y \in N} s_{xy}} \quad (22)$$

12.4.3 Ürün-Ürün (Item-Item) Modeli — Sayısal Örnek

Kullanıcı 5'in Film 1 puanı ($|N| = 2$):

1. Film 1 ortalaması $m_1 = 3.6$, satır normalize edilir.
2. En benzer 2 film: $s_{13} = 0.41$ ($r_{53} = 2$), $s_{16} = 0.59$ ($r_{56} = 3$).
3. $r_{15} = \frac{0.41 \times 2 + 0.59 \times 3}{0.41 + 0.59} = 2.59 \approx 2.6$

12.5 Performans Değerlendirme

12.5.1 RMSE

$$\text{RMSE} = \sqrt{\frac{\sum_{(x,i) \in T} (r_{xi} - r_{xi}^*)^2}{N}} \quad (23)$$

12.5.2 Precision at Top-K

RMSE'nin zaafı: çeşitliliği cezalandırmaz, bağlamı göz ardı eder, düşük puan hatalarını gereksiz yere cezalandırır. Precision@Top-K: önerilen ilk k üründen kaç gerçek kullanıcı en yüksek puanlıları arasında?

13 Sınav İpuçları

- Apriori join ve prune adımlarında tek bir alt kümenin bile elenmesi adayı budur.
- Betweenness hesaplarında alternatif yollar varsa kredi paylaşılır ($\frac{1}{2} + \frac{1}{2} = 1$).
- PageRank denklemlerinde $\sum P(i) = 1$ kısıtıyla benzersiz çözüm bulunur.
- Bloom Filtresi: False Negative imkansız, False Positive olasılığı $(1 - e^{-d/t})^k$.
- Item-Item CF, User-User'dan daha kararlıdır (ürün türleri sabit).
- RMSE her hatayı eşit cezalandırır; Precision@Top-K sadece yüksek puanlı önerilere odaklanır.