




Dil Modelleri

Prof.Dr. Banu Diri



Dil Modeli Nedir?

Bir dildeki kelimelerin sıralanışının olasılık dağılımı o dilin ***istatistiksel dil modeli*** olarak tanımlanır.

Lemma ?

Başsözcük → Sözlükteki madde başı olan kelimedir.

Başsözcükten türeyen aynı anlamdaki sözcüklere **sözcükbirim** denir.

read → reads, reading

ad soylu Türkçe bir kelimeye **24 çekim eki** eklenebilir

eylem soylu Türkçe bir kelimeye **46 çekim eki** eklenebilir

Bir dilin söz varlığı, o dildeki başsözcüklerin sayısı kadardır (**70 bin TR**)

Dilin modellenmesinin amacı

- Konuşma tanıma (Speech recognition)
- El yazısı tanıma (Handwriting recognition)
- İmla hatalarının düzeltilmesi (Spelling correction)
- Makine çeviri sistemleri (Machine translation systems)
- Optik karakter tanıma (Optical character recognizers)

El yazısı tanıma (Handwriting recognition)

Bankadaki veznedara bir not verildiğini düşünün,
ve veznedar notu “**I have a gub**” olarak okusun.
(cf. Woody Allen)

NLP burada yardımcı olur

gub ingilizcede anlamlı bir kelime değildir.

gun, gum, Gus, ve gull olabilir, fakat **gun** kelimesinin
banka ile ilişki olasılığı daha fazla olduğundan “**gub**”,
“**gun**” olarak alınır.

İmla hatalarının kontrolünde

Birbirinin yerine sıklıkla geçebilen kelimeler
piece/peace, whether/weather, their/there ...

Örnek:

“On Tuesday, the **whether** ...”

“On Tuesday, the **weather** ...”

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

W

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

Wh

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

Wha

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What d

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What do

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What do you think the next letter is?

Letter-based Language Models

Shannon's Game

Guess the next letter:

What do you think the next letter is?

Guess the next word:

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What do you think the next letter is?

Guess the next word:

What

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What do you think the next letter is?

Guess the next word:

What do

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What do you think the next letter is?

Guess the next word:

What do you

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What do you think the next letter is?

Guess the next word:

What do you think

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What do you think the next letter is?

Guess the next word:

What do you think the

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What do you think the next letter is?

Guess the next word:

What do you think the next

Harf-tabanlı (Letter-based) dil modelleri

Shannon's Game

Guess the next letter:

What do you think the next letter is?

Guess the next word:

What do you think the next word is?

-
- zero-order approximation: harflerin sıraları birbirinden bağımsız
 - xfoml rxkhrjffjuj zlpwcwkcy ffeyvkcqsghyd
 - first-order approximation: harfler birbirinden bağımsızdır, fakat dildeki (İngilizce) harflerin dağılımlarına göre meydana gelir
 - ocro hli rgwr nmielwis eu ll nbnesebya th eei alhentppa oobttva nah

-
- second-order approximation: bir harfin görülme olasılığı bir önceki harfe bağlıdır
 - On ie antsoutinys are t inctore st bes deamy achin dilonasive tucoowe at teasonare fuzo tizin andy tobe seace ctisbe
 - third-order approximation: bir harfin görülme olasılığı kendisinden önce gelen iki harfe bağlıdır
 - in no ist lat whey cratict froure birs grocid pondenome of demonstures of the reptagin is regoactiona of cre

Farklı diller için yüksek frekanslı trigram'lar:

İngilizce: THE, ING, ENT, ION

Almanca: EIN, ICH, DEN, DER

Fransızca: ENT, QUE, LES, ION

İtalyanca: CHE, ERE, ZIO, DEL

İspanyolca: QUE, EST, ARA, ADO

Dillerdeki hece benzerlikleri

Aynı aile içerisinde bulunan diller birbirlerine diğer dillere göre daha fazla benzer

Aynı aile içerisinde yer alan diller birbirlerine nasıl benzerler ?

- Hece tabanlı benzerlik

Aile içerisinde yer alan her bir dildeki en fazla kullanılan kelimeler çıkarılır;


- Kelimeler hecelerine ayrılır
- Hecelerin frekansları hesaplanır
- Heceye dayalı dildeki benzerlik hesaplanır



Örnek: Romance dilleri ailesi



Romance dillerindeki heceler



Language	The percentage covered by the first ... syllables						No. syllables	
	100	200	300	400	500	561	type	token
Latin	72%	86%	92%	95%	98%	100%	561	3922
Romanian	63%	74%	80%	84%	87%	90%	1243	6591
Italian	75%	85%	91%	94%	96%	97%	803	7937
Portuguese	69%	84%	91%	95%	97%	98%	693	6152
Spanish	73%	87%	93%	96%	98%	99%	672	7477
Catalan	62%	77%	84%	88%	92%	93%	967	5624
French	48%	61%	67%	72%	76%	78%	1738	5691

Latin-Romance Dillerinin Benzerliği









Zipf Yasası

Bir dildeki kelimelerin kullanım sıraları ve sıklıkları arasındaki ilişkiyi tanımlar George Zipf'in (1902-1950)

Zipf'in bulgularına göre kelimeler kullanım sıklığına göre sıralandıklarında **ilk sıradaki kelime, yani en sık kullanılan kelime, ikinci sıradaki kelimenin iki katı kadar kullanılıyordu.**

10 sözcükten oluşan bir dil var ve bu dilde yazılmış bir metinde en sık kullanılan sözcük 100 defa kullanılmış. En sık kullanılan kelimedenden en az kullanılan kelimeye göre yapılan sıralama listesi şöyle olacaktır:

- | | |
|--------------------------------------|--------------------------------------|
| 1. sözcük $\Rightarrow 100/1 = 100$ | 6. sözcük $\Rightarrow 100/6 = 16,6$ |
| 2. sözcük $\Rightarrow 100/2 = 50$ | 7. sözcük $\Rightarrow 100/7 = 14,3$ |
| 3. sözcük $\Rightarrow 100/3 = 33,3$ | 8. sözcük $\Rightarrow 100/8 = 12,5$ |
| 4. sözcük $\Rightarrow 100/4 = 25$ | 9. sözcük $\Rightarrow 100/9 = 11,1$ |
| 5. sözcük $\Rightarrow 100/5 = 20$ | 10. sözcük $\Rightarrow 100/10 = 10$ |

Zipf yasasının grafik yorumu



$$n(r) \propto \frac{1}{r^\alpha}$$

$$f(n) \propto \frac{1}{n^\gamma}$$


$$\gamma = 1 + \frac{1}{n^\alpha}$$

$n \rightarrow r$. sıradaki kelimenin sıklık değeri

$\alpha \rightarrow$ sabit bir değer

$\alpha \rightarrow$ yaklaşık değer

Türkçede sık kullanılan kelimelerin sıklık ve sıra ilişkisi



Kelime Tabanlı Dil Modelleri

Dil modeli, **S** cümlesinin olasılığını (likelihood/probability) hesaplamaya yardımcı olur, **P(S)**.

En basit haliyle, herbir kelime bir sonraki w kelimesini eşit olasılıkla izler (0-gram).

V sözlüğünün boyunun $|V|$ olduğunu farzedelim. Buna göre n uzunluğundaki **S** cümlesinin olasılığı (likelihood) $= 1/|V| \times 1/|V| \dots \times 1/|V|$ olarak hesaplanır.

Eğer bir dilde 100,000 kelime varsa, gelecek olan herbir kelimenin olasılığı $1/100000 = .00001$ dır.

-
- Kesin: gelecek olan her kelimenin olasılığı kelimenin frekansı ile ilişkilidir.
 - cümlenin olasılığı $S = P(w_1) \times P(w_2) \times \dots \times P(w_n)$
 - her bir kelimenin olasılığı diğer kelimelerin olasılıklarından bağımsızdır.
 - En kesin: daha önce verilmiş olan kelimenin olasılığına bakılır (n-gram).
 - S cümlesinin olasılığı $= P(w_1) \times P(w_2|w_1) \times \dots \times P(w_n|w_{n-1})$
 - her kelimenin olasılığının diğer kelimelerin olasılıklarına bağlı olduğu farzedilir.

Bir string $w_1^n = w_1 \dots w_n$ oluşsun.
Bu stringin olasılığı

$$\begin{aligned} P(w_1^n) &= P(w_1)P(w_2|w_1)P(w_3|w_1..w_2) \dots P(w_n|w_1 \dots w_{n-1}) \\ &= \prod_{k=1}^n P(w_k | w_1^{k-1}) \end{aligned}$$

Fakat bu yaklaşım genelde, bir kelime sırasının olasılığını belirlemek için çok yararlı değildir. Hesaplama maliyeti çok yüksektir.

Markov Yaklaşımı- Basit N-Grams

N-gram model, gelecek kelimeyi tahmin edebilmek için önceki N-1 adet kelimeyi kullanır.

$$P(w_n | w_{n-N+1} w_{n-N+2} \dots w_{n-1})$$

$P(\text{rabbit} | \text{I saw a})$ yerine, $P(\text{rabbit} | \text{a})$ kullanılabilir mi?

N=2 (bigram): $P(w_1^n) \approx \prod_{k=1}^n P(w_k | w_{k-1}); w_0 = \text{<start>}$

unigrams: $P(\text{dog})$

bigrams: $P(\text{dog} | \text{big})$

trigrams: $P(\text{dog} | \text{the big})$

quadrigrams: $P(\text{dog} | \text{chasing the big})$

N-Grams kullanımı

Hatırla

N-gram: $P(w_n | w_1^{n-1}) \approx P(w_n | w_{n-N+1}^{n-1})$

Bigram: $P(w_1^n) \approx \prod_{k=1}^n P(w_k | w_{k-1})$

Bigram grameri:

Cümnenin olasılığı $P(\text{cümle})$, cümle içerisinde yer alan bütün bigram'ların olasılıklarının çarpına yakın bir değerdir.

Örnek:

$P(\text{I want to eat Chinese food}) =$

$P(\text{I} | \text{<start>}) P(\text{want} | \text{I}) P(\text{to} | \text{want}) P(\text{eat} | \text{to})$

$P(\text{Chinese} | \text{eat}) P(\text{food} | \text{Chinese})$

Bigram Gramer Parçaları

Eat on	.16	Eat Thai	.03
Eat some	.06	Eat breakfast	.03
Eat lunch	.06	Eat in	.02
Eat dinner	.05	Eat Chinese	.02
Eat at	.04	Eat Mexican	.02
Eat a	.04	Eat tomorrow	.01
Eat Indian	.04	Eat dessert	.007
Eat today	.03	Eat British	.001

<start> I	.25	Want some	.04
<start> I'd	.06	Want Thai	.01
<start> Tell	.04	To eat	.26
<start> I'm	.02	To have	.14
I want	.32	To spend	.09
I would	.29	To be	.02
I don't	.08	British food	.60
I have	.04	British restaurant	.15
Want to	.65	British cuisine	.01
Want a	.05	British lunch	.01

Cümlelerin olasılığının hesaplanması

$$\begin{aligned} P(\text{I want to eat British food}) &= \\ &P(\text{I} | \langle \text{start} \rangle) P(\text{want} | \text{I}) P(\text{to} | \text{want}) P(\text{eat} | \text{to}) \\ &P(\text{British} | \text{eat}) P(\text{food} | \text{British}) = \\ &.25 \times .32 \times .65 \times .26 \times .001 \times .60 = .000080 \end{aligned}$$

$$P(\text{I want to eat Chinese food}) = .00015$$

Olasılıklar dünyanın bildiği bir gerçeği göstermektedir.

N-grams sonuçları

Sparse data

Eğitim seti içerisinde bütün N-gram'lar yer almayabilir ve bu n-gram'ların frekansı sıfır olarak alınır, bu yüzden yumuşatma (smoothing) tekniklerine ihtiyaç duyulur.

$P(\text{"And nothing but the truth"}) \approx 0.001$

$P(\text{"And nuts sing on the roof"}) \approx 0$

Örnek

Bigram grameri $V \times V$ boyutunda bir olasılıklar matrisidir.
 V , sözlük boyutu

	I	Want	To	Eat	Chinese	Food	lunch
I	8	1087	0	13	0	0	0
Want	3	0	786	0	6	8	6
To	3	0	10	860	3	0	12
Eat	0	0	2	0	19	2	52
Chinese	2	0	0	0	0	120	1
Food	19	0	17	0	0	0	0
Lunch	4	0	0	0	0	1	0

Unigram değerleri

I	Want	To	Eat	Chinese	Food	Lunch
3437	1215	3256	938	213	1506	459

$$P(w_n|w_{n-1}) = C(w_{n-1}w_n)/C(w_{n-1})$$

Computing the probability of **I I**

$$P(\mathbf{I}|\mathbf{I}) = C(\mathbf{I} \mathbf{I})/C(\mathbf{I}) = 8 / 3437 = .0023$$

Bigram Olasılık

	I	want	to	eat	Chinese	food	lunch
I	.0023	.32	0	.0038	0	0	0
want	.0025	0	.65	0	.0049	.0066	.0049
to	.00092	0	.0031	.26	.00092	0	.0037
eat	0	0	.0021	0	.020	.0021	.055
Chinese	.0094	0	0	0	0	.56	.0047
food	.013	0	.011	0	0	0	0
lunch	.0087	0	0	0	0	.0022	0

Yumuşatma (Smoothing) Teknikleri

Çok geniş bir derleme sahip olsak bile N-gram eğitim matrisi sparse bir matrisdir (Zipf's law).

Çözüm: Gözükmeyen n-gram olasılıklarını tahmin etmek

Types (V): Derlem içerisinde yer alan ayrık kelime sayısı (vocabulary size)

Token (N_T): Derlem içerisindeki toplam kelime sayısı

Şimdiye kadar gözüken kelime sayısı (T): Derlemde görülen ayrık kelime sayısı ($T \ll V$ ve N_T)

Add-one Smoothing

Her n-gram değerine **1** eklenir.

$N_T/(N_T+V)$ katsayısı ile normalize edilir


Yumuşatılmış toplam: $c_i' = (c_i + 1) \frac{N_T}{N_T + V}$
(Smoothed count)

Yumuşatılmış olasılık
(Smoothed probability): $P'(w_i) = c_i' / N_T$

Add-one Smoothed Bigrams


$$P(w_n|w_{n-1}) = C(w_{n-1}w_n)/C(w_{n-1})$$

	I	want	to	eat	Chinese	food	lunch
I	8	1087	0	13	0	0	0
want	3	0	786	0	6	8	6
to	3	0	10	860	3	0	12
eat	0	0	2	0	19	2	52
Chinese	2	0	0	0	0	120	1
food	19	0	17	0	0	0	0
lunch	4	0	0	0	0	1	0




	I	want	to	eat	Chinese	food	lunch
I	.0023	.32	0	.0038	0	0	0
want	.0025	0	.65	0	.0049	.0066	.0049
to	.00092	0	.0031	.26	.00092	0	.0037
eat	0	0	.0021	0	.020	.0021	.055
Chinese	.0094	0	0	0	0	.56	.0047
food	.013	0	.011	0	0	0	0
lunch	.0087	0	0	0	0	.0022	0

$$P'(w_n|w_{n-1}) = [C(w_{n-1}w_n)+1]/[C(w_{n-1})+V]$$



	I	want	to	eat	Chinese	food	lunch
I	9	1088	1	14	1	1	1
want	4	1	787	1	7	9	7
to	4	1	11	861	4	1	13
eat	1	1	3	1	20	3	53
Chinese	3	1	1	1	1	121	2
food	20	1	18	1	1	1	1
lunch	5	1	1	1	1	2	1



	I	want	to	eat	Chinese	food	lunch
I	.0018	.22	.00020	.0028	.00020	.00020	.00020
want	.0014	.00035	.28	.00035	.0025	.0032	.0025
to	.00082	.00021	.0023	.18	.00082	.00021	.0027
eat	.00039	.00039	.0012	.00039	.0078	.0012	.021
Chinese	.0016	.00055	.00055	.00055	.00055	.066	.0011
food	.0064	.00032	.0058	.00032	.00032	.00032	.00032
lunch	.0024	.00048	.00048	.00048	.00048	.00096	.00048

Örnek

$$P_i^* = \frac{C_i + 1}{N + V}, i = 1, 2, \dots, t$$

	Bugün	de	her	zamanki	gibi	eve	gidiyorum
Bugün	0	1	0	0	0	0	0
de	0	0	1	0	0	0	0
her	0	0	0	1	0	0	0
zamanki	0	0	0	0	1	0	0
gibi	0	0	0	0	0	1	0
eve	0	0	0	0	0	0	1
gidiyorum	0	0	0	0	0	0	0

$$P_{Bugün\ de} = \frac{1}{5}, P_{de\ her} = \frac{1}{5}, P_{her\ zamanki} = \frac{1}{5}, P_{zamanki\ gibi} = \frac{1}{5}, P_{gibi\ gidiyorum} = \frac{1}{5}$$

	Bugün	de	her	zamanki	gibi	eve	gidiyorum
Bugün	1	2	1	1	1	1	1
de	1	1	2	1	1	1	1
her	1	1	1	2	1	1	1
zamanki	1	1	1	1	2	1	1
gibi	1	1	1	1	1	2	1
eve	1	1	1	1	1	1	2
gidiyorum	1	1	1	1	1	1	1

$$P_{Bugün\ de} = \frac{2}{5 + 49} = \frac{2}{54}, P_{de\ her} = \frac{2}{54}, P_{her\ zamanki} = \frac{2}{54}, P_{zamanki\ gibi} = \frac{2}{54}, P_{gibi\ gidiyorum} = \frac{2}{54}$$

Diğer yumuşatma teknikleri: Good-Turing

Balık tutmaya çıktığınızı hayal edin...

Ve 10 tane aynalı sazan (carp), 3 tane morina (cod), 2 tane tuna, 1 tane alabalık (trout), 1 tane som balığı (salmon), 1 tane de yılan balığı (eel) yakalamış olun.

Bir sonraki yakalanacak olan balığın yeni bir tür olma olasılığı nedir ?



karşımıza 1 kez çıkan balık türü/toplam tutulan balık sayısı= $3/18$

Back-off Yöntemi

Hatırlatma : N-gram'lar her zaman (N-1) gram'a göre daha duyarlıdır.

Fakat, N-gram'lar (N-1) gram'a göre daha fazla sparse 'tır.

Bu ikisi nasıl birleştirilir ?

N-gram'ın frekans değeri uygun değilse (sıfır ise) vazgeçilir (back-off) ve (n-1) gram'a dönülür. Monogram'a kadar devam edilir. Recursive bir yapı sözkonusudur.

$$\hat{P}(w_i | w_{i-2} w_{i-1}) = \begin{cases} \tilde{P}(w_i | w_{i-2} w_{i-1}), & \text{if } C(w_{i-2} w_{i-1} w_i) > 0 \\ \alpha_1 \tilde{P}(w_i | w_{i-1}), & \text{if } C(w_{i-2} w_{i-1} w_i) = 0 \text{ and } C(w_{i-1} w_i) > 0 \\ \alpha_2 \tilde{P}(w_i), & \text{otherwise} \end{cases}$$

N-gram modelin Biçimbirimsel Belirsizliğin Giderilmesinde kullanımı

Bazı kelimelerin biçimbirimsel analizleri birden fazla olmaktadır. Doğru olanı seçebilmemiz için istatistiksel yaklaşımlardan *n-gram* modelini kullanabiliriz.

«Çoban bizim için sürüden bir **koyun** seçti»

«Oyuna devam etmek istiyorsanız beşer lira **koyun**»

- n değerini 2 alalım (n değeri büyüdükçe daha kesin sonuç alınır)
- Belirsizliği giderilecek olan kelime w_t olsun
- Derlem içerisinde w_t ve w_{t-1} peşi sıra gelme olasılığı çıkarılsın

1. cümle için

Oran	Nitelik	Oran	Nitelik	Oran	Nitelik
0,01	Fiil	0	önad	0	Bağlaç
0,5	İsim	0	belirteç	0	Yansıma
0,01	Zamir	0,001	edat	0	Özel ad
0	sayı	0,007	ünlem	0,0001	kısaltma

2.cümle için

Oran	Nitelik	Oran	Nitelik	Oran	Nitelik
0,8	Fiil	0	önad	0	Bağlaç
0,01	İsim	0	belirteç	0	Yansıma
0,01	Zamir	0,002	edat	0	Özel ad
0	sayı	0,007	ünlem	0	kısaltma