



AD: Serdar

SOYAD: Yıldız

NO: 16011004

DERS: Doğal Dil İşleme

ÖDEV NO: 1

Problem

Verilen adres veri setine uygun regex komutunu yazarak adresleri sokak, mahalle gibi parçalara ayırmaktır.

Regex Komutu

Tüm Komut:

```
(.*\sM[A]{0,1}H[.|\s|A]{0,1})| (.*\sC[A]{0,1}D[.|\s|D]{0,1})|  
(.*\sS[O]*K[.|\s|A])| (NO[.|\s|:]*)\s*[\w]*\s*[V|-]*\s*[A-Z1-9]{0,4}\s|  
(\s?[A-Z,Ç,Ğ,İ,Ö,Ş,Ü]+\s*[V])| ([^\s]*[\r\n|\r|\n])
```

Komut Açıklamaları:

Mahalle

Mahalle bilgisini ayırmak için kullanılan regex komutu,

```
(.*\sM[A]{0,1}H[.|\s|A]{0,1})
```

- M harfinden önce boşluk olması gerekmektedir.
- A harfi 1 kere olabilir veya hiç olamaz.
- H harfi olmalıdır.
- H harfinden sonra nokta boşluk veya A harfi gelebilir.

Cadde

Cadde bilgisini ayırmak için kullanılan regex komutu,

```
(.*\sC[A]{0,1}D[.|\s|D]{0,1})
```

- C harfinden önce boşluk olması beklenmektedir. İçinde CD geçen kelimelerin alınmaması için bu gereklidir.
- C harfinden sonra A harfi olabilir.
- A harfinden sonra veya C harfinden sonra D harfi bulunmalıdır.
- D harfinden sonra boşluk, nokra veya D harfi gelmelidir.

Sokak

Sokak bilgisini ayırmak için kullanılan regex komutu,

```
(.*\sS[O]*K[.|\s|A])
```

- S harfinden önce boşluk gelmesi beklenir.
- S harfi olmak zorundadır.
- O harfi olabilir ya da olmaya bilir.
- K harfi olmak zorundadır.
- K harfinden sonra boşluk, nokta veya A harfi gelebilir.

No

Numara bilgisini almak için kullanılan regex komutu,

```
(NO[\s|:|.]*\s*[\w]*\s*[V|-]*\s*[A-Z1-9]{0,4}\s)
```

- N ve O harfleri olmak zorundadır.
- O harfinden sonra boşluk, iki nokta üst üste ve noktadan bulunabilir veya hiç olmayabilir.
- Daha sonrasında boşluklar atlanır
- Boşluk gelene kadar tüm karakterler alınır.
- Boşluklar atlanır.
- "/" veya "-" gelme durumu kontrol edilir.
- Boşluklar atlanır.
- Daha sonrasında gelebilecek karakterler alınır ve bunların maksimum boyutu 4 digit olarak kabul edilir.
- Bitiş olarak boşluk olması beklenir.

İlçe

İlçe bilgisini almak için kullanılan regex komutu,

```
(\s?[A-Z,Ç,Ğ,İ,Ö,Ş,Ü]+\s*[V])
```

- İl ile ayrılabilmesi için en son karakterinin "/" olması beklenir.
- "\" karakterinden önce boşluk bulunabilir.
- Boşluklardan önce Türkçe karakterlerin de dahil olduğu bir kelime bulunmak zorundadır.

İl

İl bilgisini almak için kullanılan regex komutu,

```
([^\s]*[\r\n|\r|\n])
```

- Son kelimenin il olduğu kabul edilmiştir. Bu sebeple satır sonunun en sonda olması koşulu eklenmiştir.
- Satır sonundan boşluk olana kadar tüm karakterler dahil edilmiştir.

Başarı

Adres tanımda satır olarak tüm satırları tanıtmadaki başarısı 6831 adres içerisinde 36 adet adresi bir alt satırdaki adres ile birleştirerek yanlış tanıdığı için %99,4 tür. Bu duruma örnek aşağıdaki görsel verilebilir.

AYAZAGA MAH	MUSTAFA KEMAL ATATÜRK CAD	NO 24/B	SARIYER/	İSTANBUL
BOZHANE MAH.	ÇARŞI CAD.	NO:2	BEYKOZ/	İSTANBUL
EĞİTİM MAH.	ABDİBEY SK	NO:49/A	KADIKÖY/	İSTANBUL
FINDIKLI MAH	ÇINAR CAD	NO 37/B	MALTEPE/	İSTANBUL
CADDEBOSTAN MAH.	PROF. DRÇ HULUSİ BEHÇET CAD.	NO:2	İÇ KAPI	NO:1 KADIKÖY/ İSTANBUL
KİRAZLITEPE MAH.	TOMRUK CAD.	NO:A/1	ÜSKÜDAR/	İSTANBUL
VELİEFENDİ MAH	75 SOK	NO 25/A	ZEYTİNBURNU/	İSTANBUL
FETİH MAH	ADNAN MENDERES CAD	NO:3	ATAŞEHİR/	İSTANBUL

Başarılı sınıflandırmalara örnek olarak,

REGULAR EXPRESSION v10 31656 matches, 8867567 steps (~4.44s)

```
/(.*)M[A]{0,1}H[.|\s|A]{0,1}|(.*)S[A]{0,1}D[.|\s|.D]{0,1}|(.*)S[O]*K[.|\s|.A]|(NO[.|\s|.:]|.)*(\w)*(\w|/)*(\w)*[A-Z1-9]{0,4}\s|(\s?[A-Z,Ç,Ğ,İ,Ö,Ş,Ü]+(\w|/))*((^\s)*(\r\n|\r|\n))
```

TEST STRING

ERTUĞRUL GAZİ MAH. ATIF EFENDİ CAD. NO:41 PENDİK/ İSTANBUL
GÜZELYALI MAH. YANYOL CAD. NO:3 PENDİK/ İSTANBUL
YENİSAHRA MAH. YAVUZER CAD. NO:32/F ATAŞEHİR/ İSTANBUL
KAYIŞDAĞI MAH. EGEMENLİK SOK. NO:1/A ATAŞEHİR/ İSTANBUL
HEKİMBAŞI MAH. KÜÇÜKSU CAD. NO:371 ÜMRANIYE/ İSTANBUL
ATATÜRK CAD. YAYLA SOK. NO:3/A GÜVEN İŞ MERKEZİ ÖNÜ MALTEPE/ İSTANBUL
AYAZAĞA MAH. ATATÜRK CAD. NO:57/B SARIYER/ İSTANBUL
HAMİDİYE MAH. GİRNE CAD. NO:2/B KAĞITHANE/ İSTANBUL
ERENKÖY MAH. FAHRETTİN KERİM GÖKAY CAD. NO:292 KADIKÖY/ İSTANBUL
"YENİKÖY MAH. GÜZELCE ALİ PAŞA CAD. NO:67/A " SARIYER/ İSTANBUL
PİYALEPAŞA MAH. FATİH SULTAN CAD. NO:298/4 BEYOĞLU/ İSTANBUL
EMİRGAN MAH. BALTALIMANI CAD. NO: 74 SARIYER/ İSTANBUL
ERGENEKON CAD. NO:1/1 ŞİŞLİ/ İSTANBUL
ÇELİKTEPE MAH. İNÖNÜ CAD. NO: 53A/A KAĞITHANE/ İSTANBUL
EMİRGAN CADDESİ NO:122 SARIYER/ İSTANBUL
ALT KAYNARCA MAH. YANYOL CAD. NO:166/B PENDİK/ İSTANBUL
PİYADE ER YAŞAR YEŞİM KIR SOKAK NO:31 ZEYTİNBURNU/ İSTANBUL
İSMET PAŞA MAH. ÇİMEN SOK. NO:24 BAYRAMPAŞA/ İSTANBUL
TUNA MAH. 65 SOK NO:10 ESENLER/ İSTANBUL
NURİ PAŞA CAD. NO: 80/G SARIYER/ İSTANBUL
ABDİ İPEKÇİ CAD. NO:56 GÜNGÖREN/ İSTANBUL
MEHMET AKİF ERSOY MAH. FATİH BULVARI NO:131 SULTANBEYLİ/ İSTANBUL
YENİ MAH. ATATÜRK CAD. NO:78/B KARTAL/ İSTANBUL
BALABAN AĞA MAH. VEZNEÇİLER CAD. FATİH/ İSTANBUL

Mahalle sokak isimleri bulunmayan adresler için başarısız sonuçlar elde edilmiştir. Örnek olarak,

YENİBOSNA METRO İSTASYONU BAKIRKÖY/ İSTANBUL
KARAKÖY YER ALTI GEÇİDİ NO:24 BEYOĞLU/ İSTANBUL
YENİ DOĞAN MAH. KIŞLA CAD. NUR SANAYİ SİTESİ NO: 69 BAYRAMPAŞA/ İSTANBUL
DENİZ KÖŞKLER MAH. ESKİ LONDRA ASFALT NO: 22/3 AVCILAR/ İSTANBUL
ORTAÇEŞME SONDURAK BEYKOZ/ İSTANBUL
MEHMET AKİF ERSOY MAH. NATO YOLU BOSNA BULVARI NO: 115 ÜSKÜDAR/ İSTANBUL
DERBENT MAH. DEREİCİ OTOBÜS SON DURAK SARIYER/ İSTANBUL

Kaynak

Geliştirme ortamı olarak regex101.com kullanılmıştır.

Bağlantı: <https://regex101.com/r/QY86yX/10>

Not : grup bazlı başarı ölçülememiştir.